Estadística Matemática

Manuel Mendoza Ramírez

Departamento Académico de Estadística,
Instituto Tecnológico Autónomo de México.

Capítulo I. Elementos del Análisis Estadístico

I.1. Introducción

Los procesos de adquisición de conocimiento son diversos, pueden ser extremadamente complejos, e involucran una variedad de mecanismos que se combinan y complementan. Un elemento básico y fundamental del aprendizaje, sin embargo, es *la observación*. Desde los tiempos mas remotos, los seres humanos han acumulado conocimiento observando su entorno y, en particular, constatando que algunos eventos se repiten sin cambios cuando se observan los fenómenos de interés.

De esta manera, la reiteración de patrones y tendencias ha conducido a sugerir, y en ocasiones a dar por ciertas e inmutables, algunas *relaciones de causa-efecto*. Así, se han establecido hechos que pasan a formar parte del enorme acervo de conocimiento común.

Con este principio nuestros ancestros aprendieron que la noche sigue al día y que la falta de agua acaba con los cultivos, por ejemplo. Supieron también de las propiedades de algunos materiales, de los efectos del fuego y de la toxicidad de algunas fuentes de alimento, entre muchos otros ejemplos. La *causalidad determinística* (a una causa corresponde siempre un mismo efecto) subyace en esta forma de aprendizaje.

I.1. Introducción

Por supuesto, existe una gran diferencia entre saber que, en determinadas condiciones, siempre se produce el mismo efecto y, en otro nivel, conocer el mecanismo por el cual la causa conduce a ese efecto. Es necesario acceder a otro nivel cognitivo para resolver la segunda cuestión. Este paso equivale a transformar el conocimiento común en lo que se denomina *conocimiento científico* y debieron transcurrir muchos años antes de que la *Ciencia* se estableciera y desarrollase teorías, modelos y mecanismos para que esa transformación pudiera tener lugar.

Ahora bien, existe otra clase de fenómenos, más abundantes que los determinísticos y, por tal razón, muy importantes en lo que se refiere al aprendizaje y la adquisición de conocimiento. Estos fenómenos, aun cuando sean observados en las mismas condiciones, no necesariamente producen los mismos resultados. A una misma causa ya no corresponde un efecto único sino toda una colección de efectos posibles. Es mucho más difícil aprender de estos *fenómenos inciertos* que de los determinísticos. *La variabilidad* de sus resultados produce *incertidumbre* y, durante mucho tiempo, los seres humanos enfrentaron ese desasosiego con argumentos que incluían la magia, la fe y la resignación.

I.1. Introducción

Los ejemplos de fenómenos inciertos surgen lo mismo en el más primitivo ambiente natural que en el sofisticado entorno de la sociedad actual. A un día lluvioso, no necesariamente le seguirá otro en que llueva también. La cantidad de frutos que produce un naranjo cambia de cosecha a cosecha así se cultive con los mismos cuidados. La aplicación de un tratamiento medico no necesariamente tiene el mismo efecto en todos los pacientes y un usuario activo de las redes sociales no reacciona igual que todos los demás frente a un suceso publico. La lista es interminable.

Una discusión que reviste gran interés es la que procura identificar la fuente de la incertidumbre. ¿Es inherente al fenómeno? ¿Acaso es fruto de la ignorancia del observador, que supone que la observación se produce en las mismas condiciones cuando no es así? La materia da para disquisiciones que actualmente siguen su curso en el campo de la Filosofía. El hecho, es que los fenómenos inciertos existen, se materializan en el entorno cotidiano y, más aun, sus efectos tienen impacto en la vida de los seres humanos. Como consecuencia, y sin dejar de lado el interés por la génesis de la incertidumbre, es necesario contar con herramientas que permitan aprender y obtener conocimiento de esta clase de fenómenos.

I.1. Introducción

La observación repetida, en el caso determinístico, da paso gradualmente a la certeza de la causalidad y, como ya se ha argumentado, establece la base para el conocimiento común. Esto no ocurre de la misma manera cuando hay multiplicidad de efectos posibles. La observación repetida revela y confirma la *variabilidad* y, por tanto, la incertidumbre. El conocimiento común es de horizontes muy limitados en esas condiciones.

Es natural que incluso las ideas mas elementales que se utilizan para extraer conocimiento de los fenómenos inciertos sean mas elaboradas que sus contrapartes en un ambiente determinístico y que se hayan desarrollado mucho después, a medida que la noción de conocimiento científico se iba consolidando. De hecho, la *Estadística*, de la que nos ocuparemos en este curso, es una disciplina de carácter científico y juega un papel fundamental en el estudio de fenómenos inciertos provenientes de las mas variadas áreas de conocimiento. Como otras especialidades de la ciencia, la Estadística cuenta con sus propios conceptos, principios, métodos y técnicas y, cuando se entrevera con el estudio de otros campos, da lugar a ramificaciones diversas (Bioestadística, Econometría, Geoestadística y Astroestadística, por ejemplo) que tienen su propio desarrollo, pero retroalimentan al cuerpo principal de conocimiento estadístico.

I.1. Introducción

En una perspectiva histórica, algunos autores ubican el origen de la Estadística en el siglo XVII, con el trabajo de *John Graunt* (1662) que se ocupo del estudio de la mortalidad en Londres; en particular, del análisis de la edad al morir. A partir de una considerable cantidad de registros parroquiales, propuso la sistematización y el *resumen* de la información a través de una tabla de mortalidad, que permite entender algunos de los aspectos más relevantes de este fenómeno. Desde entonces y hasta finales del siglo XIX, el problema de producir conocimiento, a partir de observaciones provenientes de fenómenos inciertos, ha sido objeto de distintos tratamientos y aproximaciones por parte de una variedad de personajes que ocupan lugares prominentes en el desarrollo de la Ciencia. *J. Bernoulli* (1655-1705), *de Moivre* (1667-1754), *D. Bernoulli* (1700-1782), *Bayes* (1702-1761), *Laplace* (1749-1827), *Legendre* (1752-1833), *Gauss* (1777-1855), *Quetelet* (1796-1874), *Chebyshev* (1821-1894), *Galton* (1822-1911) y *Pearson* (1857-1936) son algunos de ellos.

En esta lista, con la probable excepción de *Pearson*, ninguno se haca llamar Estadístico. Mas aun, en esa época, los protagonistas del desarrollo de los métodos estadísticos se ocupaban tanto del estudio de fenómenos determinísticos como inciertos y provenían de diversos orígenes profesiones como Abogacía, Medicina, Física, Química, Astronomía, Ingeniera, Biología, Geografía o Sociología.

I.1. Introducción

Los intereses de estos precursores incluían el estudio de la mecánica celeste, la propagación de las epidemias, la valoración de la evidencia en los juicios, los procesos de la herencia biológica, la efectividad de los fertilizantes en lo cultivos e incluso los precios de los seguros, entre muchos otros más. En su trabajo, un elemento común era el interés en las Matemáticas, una herramienta fundamental para describir los fenómenos de interés.

A lo largo de esos años, la observación, la medición y la cuantificación de los fenómenos, alcanzó un papel central en el proceso de aprendizaje; especialmente, como parte del mecanismo que permite contrastar modelos y teorías con la realidad que pretenden describir. Este es un elemento clave de lo que se habría de conocer como el *Método Científico*.

En el caso de los fenómenos inciertos, parte fundamental del énfasis se colocó en la *medición de la incertidumbre*. En el proceso, se estableció una primera conexión con el cálculo de probabilidades que ya habían empezado a formalizar Pascal (1623-1662) y Fermat (1607-1665), entre otros.

I.1. Introducción

La Probabilidad, una medida de la incertidumbre, se había desarrollado sobre todo en relación a los juegos de azar. La razón para elegir ese objeto de estudio es, en la actualidad, es muy interesante desde el punto de vista pedagógico. Cada juego suele tener asociada una colección finita de resultados elementales (los efectos) que cuentan con las mismas posibilidades de ocurrir.

Estos resultados son equiprobables, de manera que la asignación de probabilidad para eventos más complejos se puede realizar calculando el cociente de casos favorables entre casos posibles. Este procedimiento reduce el problema de asignar probabilidades al de enumerar los resultados que hacen posible un determinado evento y, en su momento, dio un gran impulso a lo que ahora se denomina el análisis combinatorio. En estricto sentido, la asignación clásica de probabilidades, en virtud del supuesto de *equiprobabilidad*, no requiere la observación del fenómeno.

Todo el análisis es deductivo y se basa en la razón. Esta herramienta para la medición de la incertidumbre resultó exitosa y fructífera, con diversas ramificaciones. Estas, sin embargo, no fueron susceptibles de aplicarse a la descripción de los fenómenos naturales o sociales en general.

I.1. Introducción

Entre los obstáculos que se enfrentaron destacan dos, de naturaleza distinta. Por una parte, en el nivel conceptual, utilizar la probabilidad para describir la variabilidad de las observaciones que provienen de los fenómenos naturales presupondría que estas se producen aleatoriamente, con un mecanismo como el que da lugar a los resultados de los juegos de azar. Por otra parte, también sería indispensable suponer que los resultados elementales de estos fenómenos son equiprobables. El primer supuesto dio lugar a notables discusiones con posiciones diferentes y encontradas al respecto. Por su parte, la hipótesis de probabilidades iguales no solo ha resultado insostenible en muchas aplicaciones, sino que, de cumplirse, paradójicamente haría innecesaria la observación del fenómeno.

Cuando el estudio de la probabilidad abandonó el terreno del racionalismo puro y adoptó un enfoque mas empírico, fue posible considerar fenómenos con resultados no equiprobables. Bajo esta concepción, la probabilidad de un evento A, que puede ocurrir cuando se realiza un experimento, se define como el límite de la frecuencia relativa con que ocurre A, cuando el número de veces que se realiza el experimento (en las mismas condiciones) tiende a infinito.

I.1. Introducción

Así, el cociente casos posibles entre el número total de casos dio paso al cociente del número de observaciones exitosas entre el total de observaciones; el supuesto de probabilidades iguales se reemplazó por el de la observabilidad del fenómeno, en las mismas condiciones, una cantidad ilimitada de ocasiones. Esta modificación dejó en claro que el estudio de los fenómenos inciertos se puede llevar a cabo a partir de las observaciones que produce y tiene naturaleza inductiva (de la información particular provista por la observación, a las características generales del fenómeno).

En este punto, si bien no forma parte del temario de este curso (se revisa en el de *Estadística Bayesiana*), es importante recordar que entre las alternativas para el estudio de los fenómenos inciertos que surgieron antes del Siglo XX, ocupó un lugar destacado la idea de la *Probabilidad Inversa*. Durante los Siglos XVIII y XIX, esta noción cobró creciente importancia. Primero con *Bayes*, pero especialmente con *Laplace*, se estableció esta línea de pensamiento que, retomando la relación causa-efecto, propone que, en el caso de los fenómenos inciertos, una descripción probabilística de los efectos posibles cuando se conoce la causa, combinada con una descripción de la incertidumbre inicial respecto a la causa desconocida, podía dar lugar a una descripción actualizada de la incertidumbre sobre la causa, dada una colección de efectos (datos) observados.

I.1. Introducción

Ese enfoque establece un mecanismo para llevar a cabo este proceso de aprendizaje. Este se reduce a la, ahora muy conocida, formula de Bayes. Citando al propio Laplace (1774):

“If an event can be produced by a number k of different causes, the probabilities of these causes given the event are to each other as the probabilities of the event given the causes".

Esta aproximación al estudio de los fenómenos inciertos fue desplazada, al filo del Siglo XX, por las ideas de la Estadística que vamos a revisar en este curso y que se conocen, en su conjunto, como Estadística Frecuentista o Estadística Matemática. Se trata de la escuela de pensamiento dominante durante la mayor parte del siglo pasado; ha sido extraordinariamente eficaz y reúne una variedad de ideas brillantes que surgen de los diferentes problemas específicos que aborda. Establece criterios precisos para evaluar la optimalidad de sus procedimientos y se desarrolla con rigor matemático. En la práctica ha sido muy exitoso, en particular debido a que sus métodos están al alcance de los usuarios a través de una gran cantidad de aplicaciones de cómputo. Por otra parte, es conveniente reconocer que este enfoque también tiene, como es natural, algunas limitaciones que se señalarán oportunamente.

I.2. La Naturaleza del Análisis Estadístico

La Estadística es una disciplina científica que sirve para aprender de los fenómenos inciertos. En prácticamente todos los textos de Estadística se incluye una descripción de lo que los distintos autores entienden por Estadística. Lo mas curioso, quizá, es que sus descripciones tienen un grado de generalidad y una falta de precisión que no corresponden con un texto de aspiraciones científicas. Veamos algunos casos:

- R.A. Fisher (1925/1970): *"The science of statistics is essentially a branch of Applied Mathematics and may be regarded as mathematics applied to observational data"*.

- G.W. Snedecor y W.G. Cochran (1937/1967): *"...Statistics deals with techniques for collecting, analyzing, and drawing conclusions from data".*

- Mood, A.M., Graybill, F.A. y Boes, D.C. (1974): *"One function of Statistics is the provision of techniques for making inductive inference and for measuring the degree of uncertainty of such inferences".*

I.2. La Naturaleza del Análisis Estadístico

Estas descripciones, lo mismo que las que parecen en muchos otros textos, con diferentes grados de especificidad, proveen elementos para familiarizarse con la disciplina. Dan cuenta de como podría ser considerada, establecen que su materia prima son los datos. Señalan una función de la Estadística. Sin embargo, no la caracterizan, como sería de esperarse de una definición formal. Esta falta de precisión no deja de ser peculiar, especialmente si se toma en cuenta, por un lado, el rigor matemático con que estos textos desarrollan su contenido y, por otra parte, el tiempo que ha transcurrido desde que la Estadística se estableció como un instrumento fundamental para la adquisición de conocimiento científico. De cualquier forma, sea cual sea la causa de esta anomalía, en este curso adoptaremos una definición, formal y precisa, a la que recurriremos constantemente para contrastar las ideas centrales en el desarrollo de los distintos temas:

Definición 1.1. *La Estadística es una disciplina cuyo propósito es* ***describir*** *fenómenos que se manifiestan a través de datos que presentan* ***variabilidad****.*

Esta caracterización delimita, puntualmente, el ámbito de acción –los fenómenos que presentan *variabilidad*- y, al mismo tiempo, establece el objetivo que se persigue: la *descripción*.

I.2. La Naturaleza del Análisis Estadístico

De esta forma, un procedimiento para el análisis de datos se puede identificar como parte del acervo estadístico si,

- Su objetivo es la *descripción* del fenómeno que originó los datos,
- Los datos con que realiza el análisis presentan *variabilidad.*

De esta forma, los dos términos clave son *descripción* y *variabilidad*. Si se cae en la tentación del *glamour*, se puede sustituir la palabra disciplina en la definición por la de *Ciencia*. En el otro extremo, ni ciencia, ni disciplina, sino simplemente un conjunto de técnicas. Una consecuencia de esta definición, es que *toda la Estadística es descriptiva*, idea que se contrapone con la división que algunos viejos textos en la materia establecen cuando separan lo que ellos denominan Estadística Descriptiva de la Inferencia Estadística. La definición es general y aplica para todos las componentes de la disciplina. Antes de iniciar la presentación de las técnicas de que se sirve la Estadística para cumplir su cometido, es pertinente presentar algunas ideas generales.

I.2. La Naturaleza del Análisis Estadístico

Cuando se aborda el estudio de un fenómeno, habitualmente esta tarea se acomete con un objetivo específico y con información previa que puede proceder de diversas fuentes. Estos dos elementos determinan el Marco de Referencia de la investigación.

El tema es relevante porque un fenómeno se puede manifestar en una variedad de formas distintas, pero es precisamente el marco de referencia el que establece los atributos que son de interés en un estudio particular

Como ejemplo, considere un estudio con el que interesa describir el sistema de salud público del país. Antes de realizar la investigación es muy probable que exista información sobre algunos temas relacionados, proveniente de diversas fuentes y con distintos niveles de calidad. En cuanto a los objetivos, estos pueden ser de naturaleza muy variada. Si el estudio lo patrocina un proveedor internacional de suministros médicos, es posible que el interés se concentre en las oportunidades de negocio que se puedan concretar con el sector. En otro extremo, si el proyecto lo desarrolla una institución académica de investigación, el objetivo podría estar ligado a la eficiencia con que el sector atiende las necesidades de la población.

I.2. La Naturaleza del Análisis Estadístico

Así, en el caso del proveedor, el atributo de interés sería el *Potencial de Negocio*, mientras que para la investigación académica, el atributo que interesa es la *Eficiencia del Sector*.

Definición 1.2. *En general, se define un Atributo de Interés como un rasgo a través del que se busca describir el fenómeno bajo estudio.*

Los atributos son de tipos muy variados y pueden cambiar de un estudio a otro, lo mismo que en una misma investigación, a lo largo del tiempo. Con frecuencia, como en los ejemplos del Potencial y la Eficiencia, se definen en términos conceptuales. Pero aun cuando se refieran a aspectos en apariencia más tangibles, es necesario precisar con detalle la forma en que serán registrados en el estudio. Suponga que en el estudio del sector salud, el atributo de interés es el *Tamaño del sector*. Parece un concepto claro, básico, sin embargo, vale la pena considerar las siguientes preguntas: ¿Qué es el tamaño del sector salud?, ¿Cómo se determina? ¿Cómo se puede observar?

No es difícil reconocer que el tamaño se puede definir cuando se le considera como sector económico o por su cobertura de servicios, entre otras muchas posibilidades. El hecho, es que todo atributo requiere otro nivel con mayor especificidad para definir como se habrá de medir, observar y registrar el fenómeno.

I.2. La Naturaleza del Análisis Estadístico

Este nuevo nivel de especificidad se conoce con el nombre de *Variable*.

Definición 1.3. *Una Variable es una codificación **numérica** específica de un atributo que puede ser registrada cada vez que se observa el fenómeno bajo estudio.*

Un atributo puede ser registrado a través de una o más variables. En cualquier caso, es conveniente insistir en que, por definición, toda variable es *numérica*. Esta propiedad permite que los métodos estadísticos sean generales y no particulares de cada investigación.

Ahora bien, todas las variables son codificaciones numéricas, pero no todas son del mismo tipo. Por ejemplo, si interesa el tamaño del sector salud en términos de su cobertura, una variable podría ser el número de hospitales de tercer nivel en el país; otra posibilidad es el porcentaje de localidades con menos de mil habitantes que cuentan con una clínica de primera atención y una más podría ser una variable que tome el valor uno si el sarampión está erradicado o cero si aun se presentan casos. En todos estos ejemplos el resultado es una codificación numérica pero no todas tienen la misma naturaleza.

I.2. La Naturaleza del Análisis Estadístico

El número de hospitales es una codificación numérica de naturaleza realmente cuantitativa discreta. El porcentaje de localidades es también cuantitativa pero puede considerarse continua. En ambos casos se pueden analizar los valores que producen estas variables utilizando las operaciones aritméticas habituales.

Por su parte, la variable que se relaciona con el sarampión, si bien emplea códigos numéricos, no representa una cantidad sino una cualidad y no es susceptible de tratarse libremente con las operaciones aritméticas. Los métodos estadísticos reconocen estas diferencias entre las variables y las incorporan en el análisis.

Vale la pena insistir en que una variable no esta definida sino hasta que establece, por completo, la codificación con que registra el atributo de interés. Como ilustración, cuando se trata de la talla de las personas, la *Estatura* no es una variable hasta que no se define como y con que unidades de habrá de registrar (en metros y centímetros, en pies y pulgadas, o como un código 0 si no supera un metro y medio, y un código 1 en caso contrario, por ejemplo).

I.2. La Naturaleza del Análisis Estadístico

Finalmente, se tiene la idea de los *Datos* que siempre se asocian al proceso de observación de los fenómenos.

Definición 1.4. *Un Dato es el resultado específico de la observación de una variable concreta en un caso particular.*

De esta forma se establece la secuencia jerárquica: *Atributos* $\Longrightarrow$ *Variables* $\Longrightarrow$ *Datos,* que se representa en la Figura 1 y resulta vital para el diseño de una investigación, en particular si la investigación es estadística. Es conveniente recordar que la materia de estudio de la Estadística son los fenómenos cuyos resultados presentan variabilidad. Es por esta razón que la observación repetida juega un papel fundamental en la realización de los estudios estadísticos. Si no hubiese variabilidad, una sola observación bastaría para producir la descripción deseada (y establecer la consiguiente relación causa-efecto). Como no es este el caso, el estudio necesariamente requiere la observación repetida que produce una colección de datos (con variabilidad).

I.2. La Naturaleza del Análisis Estadístico

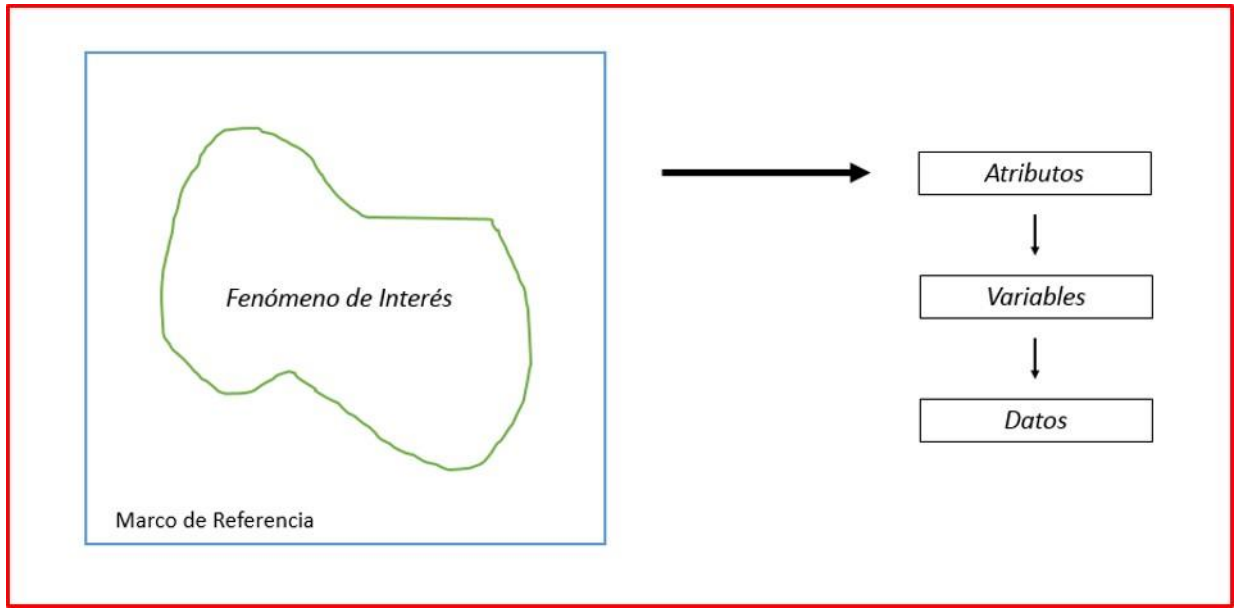

Figura 1. *El proceso de Observación.*

En lo sucesivo, emplearemos letras mayúsculas para referirnos en forma genérica a las variables en el estudio $(W, X, \dots, Z)$ y, en correspondencia, letras minúsculas para los datos que se obtienen al observar cada una de esas variables $(w, x, \dots, z)$. Así, si se tiene un atributo A, que se registra a través de la variable X, los datos que se obtienen a partir de la observación (repetida n veces) resultan $x_1, x_2, \dots, x_n$.

I.2. La Naturaleza del Análisis Estadístico

Volviendo al objetivo del estudio, este es *describir* el fenómeno. Para ello se produce la observación y con el resultado, los datos, se aborda la descripción, tal como se ilustra en la Figura 2.

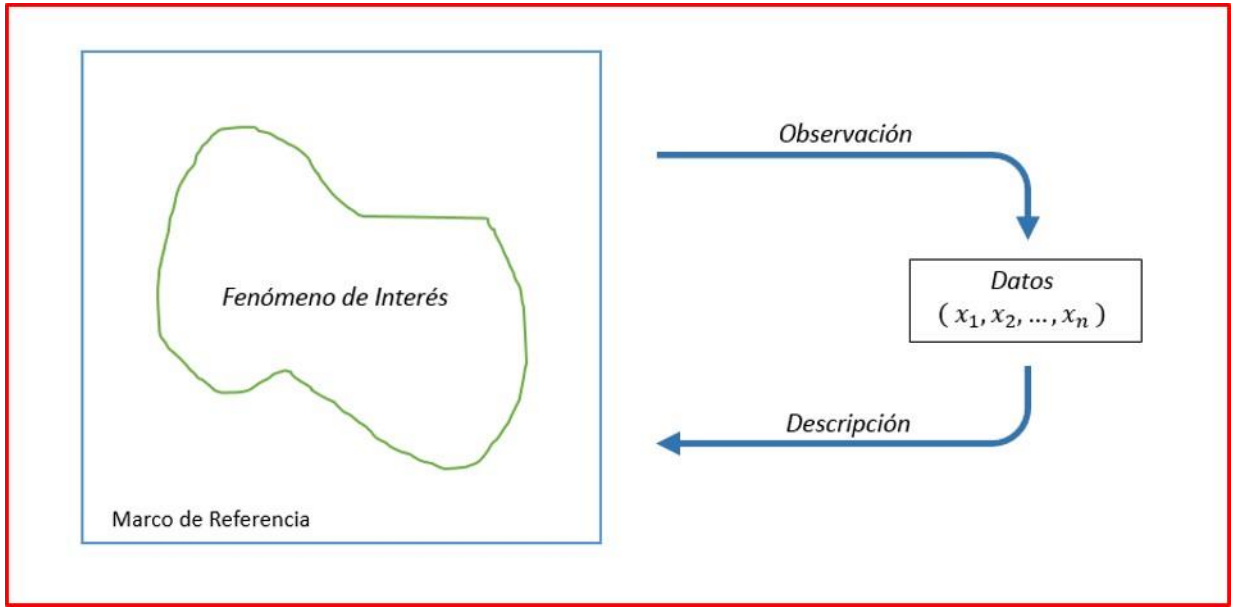

Figura 2. *El ciclo Observación-Descripción.*

I.2. La Naturaleza del Análisis Estadístico

Una vez que el fenómeno se observa a través del atributo A, la descripción se ha de producir necesariamente en referencia a ese atributo. En la misma línea, cuando A se registra mediante la variable X, la tarea de la Estadística es ahora describir esta variable. Finalmente, la información disponible sobre X es la que proveen los datos, así que la descripción del fenómeno, en última instancia, se produce al describir la colección de datos $x_1, x_2, \dots, x_n$.

Puesto que los datos no son todos iguales, pudiera pensarse que su mejor descripción es simplemente el listado completo de todos ellos. Esta es una posibilidad que puede tener sentido cuando la cantidad de datos es pequeña, pero si n crece, el conjunto de datos eventualmente alcanzara un volumen tal que un examen de los datos, uno por uno, será complicado, con frecuencia, inútil y en un extremo, imposible.

La solución general que los estadísticos han propuesto para este problema es natural y consiste en la producción de *resúmenes* (gráficos o numéricos) de los datos.

I.2. La Naturaleza del Análisis Estadístico

Por supuesto, esos resúmenes deben capturar las características relevantes para el investigador. Así que, tres ideas que se deben mantener presentes a lo largo de todo el texto son las siguientes:

- *Las descripciones que produce la Estadística se refieren a los fenómenos de interés, pero se concretan a través de la descripción de los datos, fruto de la observación.*

- *Las técnicas y métodos estadísticos son especialmente útiles cuando el volumen de datos es grande.*

- *La Estadística describe los conjuntos de datos a través de resúmenes.*

En particular, en relación con el tercer apartado, vale la pena anotar que cuando se estudia la disciplina Estadística, como lo haremos en este curso, lo que en realidad se investiga son las ideas, los conceptos, los métodos y las técnicas para producir los mejores resúmenes de los datos, los resúmenes óptimos. Este apunte es relevante porque la Estadística es una disciplina científica y, en consecuencia, el conocimiento que produce debe tener esta calidad, *óptima*.

I.2. La Naturaleza del Análisis Estadístico

En cada estudio particular es posible que se puedan producir distintos resúmenes; unos buenos, otros mediocres y algunos otros, muy pobres. Si, como ejemplo, es de interés la talla (atributo) de los 560 estudiantes varones de licenciatura en una universidad, y la variable que se registra en cada uno de ellos es la estatura, en metros y centímetros, es razonable suponer que los 560 datos presentarán variabilidad (se trata de un estudio estadístico). También es claro que un resumen posible de estos datos, es la media (la estatura promedio). Sin embargo, no es automático que este resumen sea el mejor. Si el estudio se realiza para decidir sobre la pertinencia de organizar un equipo de baloncesto que represente al programa, seguramente, un resumen mas útil sería la fracción de estudiantes que superan el 1.90 metros de estatura.

El objetivo de la Estadística en esta materia es producir, en cada caso, los resúmenes óptimos. Por supuesto, para asegurar que un resumen es el mejor, será indispensable establecer criterios para evaluarlos y, además, será necesario tomar en cuenta, tanto la naturaleza de las variables que se analizan, como los objetivos del estudio. En general, se puede afirmar que los mejores resúmenes serán los que, en el menor volumen, conserven toda la información relevante. Los que tengan la mayor capacidad de síntesis, sin perder información valiosa. Utilizando los términos técnicos que se precisaran mas adelante, los mejores resúmenes son los *suficientes* y *minimales*.