I.3. Dos Vertientes de la Estadística

Como ya se estableció, toda la Estadística es descriptiva y la descripción que produce se realiza a partir de los datos. Ahora bien, existen dos casos que es extraordinariamente importante distinguir.

Por una parte, en algunos estudios es posible acceder a todos los datos que el fenómeno puede producir. En el lenguaje estadístico, se dice que se cuenta con un Censo o que se observó la Población de Interés en su totalidad.

Los ejemplos mas obvios de este tipo son precisamente los Censos de Población y los Censos Económicos que periódicamente se realizan en las diferentes naciones y por medio de los cuales, en los primeros, se registra el sexo, la edad y otras características de *todos* y cada uno de los habitantes del país. En los censos económicos, por su parte, se obtiene información de *todas* las unidades económicas del país sobre su giro, su producción y sus ventas, entre otros aspectos. Los censos de población y económicos son estudios enormes, pero existen otros ejemplos de alcance mucho menor, en los que no solo es posible sino forzoso realizar un censo. Cuando una empresa está evaluando sus pasivos contingentes, en particular sus pasivos laborales, como parte del estudio recabará información de *todos* sus empleados. Así, registrará las edades, los salarios y los años de antigüedad, para todos sus empleados, sin importar su número.

I.3. Dos Vertientes de la Estadística

En cualquier caso, cuando se lleva a cabo un censo, y por tanto, se tiene la información completa sobre el fenómeno de interés, la descripción que se produce de los datos equivale a una *descripción exacta* del fenómeno. Por supuesto, habrá sido necesario elegir los resúmenes óptimos, atendiendo a los objetivos del estudio y a la naturaleza de las variables que se registran pero, una vez con ellos, la descripción que se produce es un reflejo fiel del fenómeno y el estudio finaliza.

Las técnicas estadísticas que se aplican en estas circunstancias constituyen la primera de las dos vertientes a las que se refiere el título de esta sección, se agrupan bajo la denominación general de Análisis Exploratorio de Datos y se presentan en una diversidad de textos. Una referencia clásica es el libro de Tukey (1977), si bien existen libros más recientes que hacen uso de los recursos modernos de cómputo. El tema es de gran interés y de suma utilidad. Sin embargo, no es el objeto de estudio en este curso.

Análisis Exploratorio de Datos $\Longrightarrow$ *Descripción Exacta*

I.3. Dos Vertientes de la Estadística

El otro tipo de estudio, cuando se trata de un análisis estadístico, que entraña aun más retos y del que nos vamos a ocupar en lo que resta de este curso, ocurre cuando no es posible recolectar todos los datos que puede producir el fenómeno de interés. Las causas que impiden observar todos los datos pueden ser de lo mas variadas. El costo puede ser un factor.

Imagine que un partido político esta interesado en conocer las preferencias electorales en una localidad como la Ciudad de México, que en 2018 contaba con mas de 7.5 millones de electores registrados. Convocar a todos esos ciudadanos para que expresen sus preferencias, equivale a organizar una votación completa, un ejercicio extremadamente costoso. Lo habitual, en estos casos, es entrevistar a unos pocos centenares de electores y utilizar sus opiniones como un referente de lo que opina la totalidad de los electores. En este punto, vale la pena introducir otra definición.

Definición 1.5. *Cuando sólo se tiene acceso a una fracción de los datos que el fenómeno puede generar, cuando solamente se observa una parte de la Población de Interés, a la fracción observada se le denomina* ***Muestra****.*

I.3. Dos Vertientes de la Estadística

Otro ejemplo, en el terreno farmacéutico, en el que no tiene sentido considerar un censo, se presenta cuando se ensayan medicamentos nuevos. Suponga que se tiene una nuevo tratamiento contra la influenza y se desea valorar el efecto que tiene en personas adultas, de origen hispánico, con síntomas claros del padecimiento, que no presenten otra enfermedad concurrente.

El problema es que, al momento del estudio (sea este cual sea), el grupo completo de los individuos que forman la población de interés no se encuentra al alcance del estudio. No solamente es inviable incluir a todas las personas que tengan ese perfil en el país (o en el planeta), sino que habrá personas que cumplan los requisitos en el futuro pero que, en ese momento, todavía no existen. En estas condiciones, un censo es imposible. Una alternativa es probar el tratamiento en un grupo reducido de personas (la *muestra*), con la idea de que los resultados se puedan hacer extensivos a todos los pacientes de su tipo, actuales o futuros.

En el área de control de calidad también se presentan problemas de este tipo. En términos simples, el control de calidad es un proceso que se aplica a un producto con el objetivo de establecer si cumple con una serie de especificaciones (de calidad).

I.3. Dos Vertientes de la Estadística

Suponga que en una industria se fabrican tabletas electrónicas que se comercializan con la garanta de que, bajo ciertas condiciones ambientales, se mantienen operando sin fallas, por al menos 100 horas continuas. En este caso, el control de calidad tiene, entre otros objetivos, la misión de verificar que el porcentaje de productos que no alcanzan ese estándar es tan pequeño que las pérdidas por incumplimiento de la garanta representan un riesgo aceptable. Para determinar si una tableta cumple con la norma, es necesario mantenerla en funcionamiento, en las condiciones prescritas, hasta que falle o alcance el límite de las 100 horas.

El asunto es que, sea cual sea el resultado, esa tableta, una vez que se sometió a la prueba de calidad, ya no es comercializable. La prueba es *destructiva* y, por supuesto, en ningún caso un fabricante estará dispuesto a destruir la *totalidad* de su producción, ni siquiera si cree que, al final, todas las tabletas habrán superado la prueba satisfactoriamente.

En la práctica, las pruebas de control de calidad son indispensables y para obtener datos, la prueba se aplica solamente a una muy pequeña fracción de la producción completa (de nuevo una muestra) y los resultados se utilizan para describir a la totalidad de las tabletas producidas o por producir.

I.3. Dos Vertientes de la Estadística

Otros casos, donde la observación destructiva ocurre cotidianamente, se presentan en Medicina. Como ilustración, considere los exámenes de sangre. Cuando un médico le solicita a una persona que se practique una prueba de química sanguínea, lo que busca son datos que le permitan describir el funcionamiento del organismo de su paciente. Los resultados de un examen de este tipo suelen incluir información sobre la densidad de eritrocitos, leucocitos y plaquetas. Con frecuencia reportan también concentraciones de glucosa, lípidos y triglicéridos entre otros elementos.

Como sabe todo aquel que ha pasado por estas experiencia, para obtener estas mediciones no se realiza un censo. No se extrae toda la sangre (entre cuatro y cinco litros) del paciente sino que se obtiene solo una muestra (habitualmente de no mas de unos pocos mililitros.

En resumen, entre las causas que impiden la realización de los censos se encuentran su costo, la inaccesibilidad de la población de interés y la destrucción de los elementos que son objeto de la observación.

I.3. Dos Vertientes de la Estadística

Podríamos continuar con una larga lista de estudios en los que la idea de realizar un censo para describir el fenómeno de interés es inaceptable. Sin embargo, con los ejemplos a la mano ya es posible concluir que, aun cuando no sea posible un censo, la necesidad de describir los fenómenos inciertos correspondientes permanece y, por tanto, el reto de la Estadística en este caso es diseñar métodos y técnicas para producir la descripción que interesa con la *información parcial e incompleta* que ofrece una muestra. En otras palabras, la disciplina debe contar con la capacidad para describir fenómenos en lo general, a partir de colecciones de datos parciales. Las técnicas, métodos y procedimientos que se ocupan de este problema se agrupan bajo la denominación de *Inferencia Estadística,* cuyo estudio será nuestro centro de atención este semestre.

Antes de abordar sus procedimientos específicos, vale la pena establecer algunas ideas generales que caracterizan a la Inferencia Estadística. Como en cualquier otro caso, cuando se han definido los resúmenes óptimos para el problema particular, estos pueden ser utilizados para describir la muestra a la que se tiene acceso y, de acuerdo con el Análisis Exploratorio de Datos, la descripción que producen será *exacta en tanto se refiera a la muestra*.

I.3. Dos Vertientes de la Estadística

El objetivo, sin embargo, no es describir la muestra sino describir la población completa (el fenómeno en su totalidad) a partir de la información comprendida en la muestra. Así que el siguiente paso es fundamental y consiste en extrapolar la descripción de la muestra para describir la población completa. En este punto es evidente la mas importante diferencia de la Inferencia Estadística con el Análisis Exploratorio de Datos: Sin importar la forma en que se haya seleccionado la muestra ni el mecanismo concreto de extrapolación, la descripción de la población es, en el mejor de los casos, aproximada.

Inferencia Estadística $\Longrightarrow$ *Descripción* ***Aproximada***

Por ejemplo, en el caso del estudio de preferencias realizado por el partido político, si el 27% de los electores en la muestra declara que votaría por el partido, ese porcentaje describe *exactamente* lo que manifiestan las personas en la muestra. Sin embargo, si ese porcentaje se utiliza para describir las preferencias de *todos* los electores, es necesario reconocer que, aun si la muestra refleja razonablemente lo que ocurre en el conjunto de todos los electores, solamente se puede decir que *aproximadamente* el 27% de los electores en la población piensa votar por el partido.

I.3. Dos Vertientes de la Estadística

De esta manera, la diferencia fundamental entre las dos vertientes de la Estadística (Análisis Exploratorio de Datos e Inferencia Estadística) radica en el hecho de que la descripción que producen de los fenómenos es, en el primer caso, exacta y en el segundo, *solamente aproximada*.

Y el asunto no para ahí. Reconocer que la descripción es aproximada es de la mayor importancia pero resulta irrelevante en la práctica, si no es posible contar con una idea razonable y útil del grado de aproximación que implica.

¿Qué significa la afirmación de que aproximadamente el 27% de los electores piensa votar por el partido? En la población completa, ese porcentaje ¿Se encuentra entre 25% y 29%? ¿Entre 4% y 50%? y, de ser correcto alguno de estos casos ¿Qué tan seguros podemos estar de ello?

I.3. Dos Vertientes de la Estadística

Así, un primer reto específico de la Inferencia consiste en medir, en cuantificar, el grado de aproximación que tienen las descripciones que produce. Una idea que aparece de forma natural en relación con este desafío, es la noción, *correcta*, de que la aproximación será mejor en la medida en que la muestra refleje mejor lo que ocurre en la población. De hecho, si la muestra fuese una reproducción exacta, a pequeña escala, de la población completa, entonces la descripción resultaría también exacta. A una muestra con esa propiedad ideal se le denomina *representativa.*

De este razonamiento impecable, surge una quimera. Todo investigador enfrentado a un problema de inferencia quisiera contar con muestras representativas. Y es un desvarío, porque la única forma de asegurar que una muestra es representativa, requiere el conocimiento de la población completa, en cuyo caso el problema de inferencia simplemente se desvanecería. Así que las muestras representativas, deseables sin duda, *no se pueden garantizar en la práctica* y anunciar que un estudio se realiza con una muestra representativa es un despropósito.

No obstante, durante algún tiempo la selección de la muestra se llevaba a cabo con la asesoría de expertos, conocedores de algunos rasgos generales de la población de interés que, con esa información, seleccionaban muestras, con aspiraciones de representatividad.

I.3. Dos Vertientes de la Estadística

Esta práctica tenía, y tiene, al menos dos inconvenientes. Por una parte, no garantiza la reproducibilidad del estudio. Dos expertos pueden diseñar muestras distintas y no hay forma de establecer si las diferencias entre los resultados correspondientes son reconciliables. El segundo inconveniente, que se relaciona con el primero, es que con una muestra *experta* sigue sin respuesta el problema de medir el grado de aproximación de la inferencia que se produce.

Por supuesto, existen ejemplos donde un experto seleccionó una muestra que fue tratada como representativa y condujo a resultados con un nivel de aproximación (verificada *a posteriori*) extraordinario. Desafortunadamente, los casos en que se puede realizar esa verificación *postmortem*, son la excepción y, peor aun, lo deseable es contar con una buena opinión acerca de la calidad de la muestra antes de realizar el estudio, no después.

De cualquier manera, recurrir a un experto por eficaz y confiable que sea, no es una alternativa recomendable para acumular los datos que darán lugar a una pieza de conocimiento científico. Depender de una persona específica para producir resultados, además de contravenir la idea de reproducibilidad que ya se ha mencionado, introduce un factor de fragilidad indeseable.

I.4. El Muestreo Probabilístico

Para fortuna de los usuarios de los métodos estadísticos, los retos que, de origen, entraña la inferencia fueron razonablemente resueltos en las primeras décadas del siglo XX y, más aun, el procedimiento propuesto provee una solución, simultánea, al tema de la selección de la muestra y al de la medición del grado de la aproximación en la inferencia.

Es conveniente reconocer que, a lo largo del tiempo, una gran cantidad de estadísticos contribuyeron a la solución definitiva y que, en alguna forma, el asunto quedo zanjado en 1934, tras la publicación del artículo de Jerzy Neyman que se considera un hito en el tema. El título resulta evocador cuando se conoce el problema: *On the Two Different Aspects of the Representative Method: The Method of Stratified Sampling and the Method of Purposive Selection.*

La solución consiste en seleccionar la muestra por sorteo o, en un lenguaje mas técnico, en utilizar un procedimiento de *selección probabilística de la muestra*. Las consecuencias de esta idea, tanto conceptuales, técnicas y prácticas, son extraordinarias y, en buena parte, serán nuestro principal objeto de estudio. La versión mas sencilla del muestreo por sorteo se puede describir muy fácilmente.

I.4. El Muestreo Probabilístico

Suponga que el conjunto completo de todas las observaciones que puede producir un fenómeno es finito, pero muy grande, de tal forma que hace inviable la realización de un censo. Si de ese conjunto que, digamos, consta de N elementos, se desea seleccionar una muestra de tamaño n $(n << N)$, se procede como sigue:

1. Se identifica a cada elemento en la población con una, y solo una, etiqueta en el conjunto $\{1, 2, \dots, N\}$.
2. Se depositan las N etiquetas en una urna.
3. Después de asegurar que han sido bien mezcladas, se extrae una etiqueta, que identifica al primer elemento que formara parte de la muestra.
4. Se procede de igual manera con las $N - 1$ etiquetas restantes en la urna para identificar al segundo integrante de la muestra.
5. Se repite el procedimiento hasta identificar a todos los elementos que formaran la muestra de tamaño n.

I.4. El Muestreo Probabilístico

El mecanismo equivale a un experimento aleatorio a través del que se obtiene una muestra de tamaño n, sin reemplazo, de elementos en la población. La información de interés se obtiene al realizar la observación de la variable X, en cada uno de los elementos seleccionados, lo que dará origen a la colección de datos $x_1, x_2, \dots, x_n$.

Una primera consideración, que conceptualmente es de la mayor importancia, es que bajo este esquema no es necesario suponer que el fenómeno bajo estudio produce sus observaciones en forma aleatoria. Los datos presentan variabilidad, como ya se ha discutido, pero la aleatoriedad es debida a, y garantizada por, el mecanismo de selección de la muestra. De hecho, a una muestra de este tipo se le denomina una *muestra aleatoria*. El resultado es fundamental puesto que la naturaleza aleatoria de las observaciones está garantizada, es independiente del fenómeno y el empleo de la probabilidad para describirlas es inmediato.

Un segundo aspecto no menos relevante tiene que ver con la relación que guardan las muestras aleatorias con la idea de representatividad de la muestra. Como ya hemos comentado, no es posible afirmar que una muestra es representativa a menos que se conozca la población completa.

I.4. El Muestreo Probabilístico

Ni siquiera en el caso del muestreo probabilístico se puede decir que las muestras que produce sean representativas. Sin embargo, con este algoritmo cada elemento de la población tiene la misma probabilidad de ser incluido en la muestra y, como consecuencia, los valores de X mas frecuentes en la población serán necesariamente los mas probables en la muestra. Es decir, *lo más probable* es que la muestra resulte parecida a la población. En otras palabras, no hay garantía, pero lo más probable es que la muestra se aproxime a la quimera de la representatividad.

Por otra parte, el mecanismo es reproducible y exógeno; no existe la posibilidad de un sesgo deliberado en la selección de la muestra. Ya que en cada paso de la selección de la muestra se realiza un experimento aleatorio, el dato correspondiente al i-ésimo paso, x_i, se puede considerar la realización de una variable aleatoria X_i para $i = 1, .2, \dots, n$. Más aun, puesto que n cumple la condición $n << N$, es razonable suponer que el contenido de la urna no cambia tras cada extracción y entonces, las variables $X_1, X_2, \dots, X_n$ son independientes e idénticamente distribuidas.

Equivalentemente, se puede suponer que los datos, $\underline{x}_{(n)} = \{x_1, x_2, \dots, x_n\}$ son el resultado de observar n realizaciones independientes $\underline{X}_{(n)} = \{X_1, X_2, \dots, X_n\}$ de una misma variable aleatoria X.