I.4. El Muestreo Probabilístico

En efecto, a partir de ahora se adoptará la siguiente

Definición 1.6. *Se dice que* $\underline{X}_{(n)} = \{X_1, X_2, \dots, X_n\}$ *es una muestra aleatoria (m.a.) de la variable aleatoria* X*, si constituye una colección de variables aleatorias independientes e idénticamente distribuidas (i.i.d) de acuerdo a la función de la distribución de* X*.*

Esta formulación tiene efectos muy importantes en el proceso de inferencia. Originalmente, la investigación tiene como propósito describir el fenómeno de interés. En cuanto se fija el atributo a través del cual se va a registrar el fenómeno, el objetivo es describir el atributo. En el siguiente nivel, una vez que se define la variable que precisa el atributo, la descripción que se persigue es la de esa variable. Si fuese posible realizar un censo, se conocerían todos los datos que la observación de la variable puede producir y con ellos se alcanzara la meta.

En nuestro caso, de muestreo probabilístico, solamente tenemos acceso a una muestra aleatoria de la variable aleatoria X. Así, entonces, a partir de la información muestral, es necesario producir una descripción (aproximada) de todos los datos que X puede producir.

I.5. Inferencia Paramétrica

Se busca una descripción de los valores distintos que puede tomar la variable y de la frecuencia con que se presentan en la población. En términos técnicos, interesa describir el soporte de X y la probabilidad con que produce cada uno de los valores en ese soporte. En resumen, el objetivo del estudio se reduce a describir la *Función de Distribución* $F(x)$.

El objetivo es mas específico, pero no mas simple; determinar la distribución de una variable aleatoria a partir de un puñado de observaciones es un problema complejo. El conjunto $\mathcal{F}$ de todas las funciones de distribución cuenta no solo con un numero infinito de elementos, sino que es de dimensión infinita. Se trata de la colección de todas funciones que satisfacen las condiciones:

- $F(x)$ monótona no decreciente.
- $F(x) \longrightarrow 0$ cuando $x \longrightarrow -\infty$.
- $F(x) \longrightarrow 1$ cuando $x \longrightarrow \infty$.
- $F(x)$ continua por la derecha.

I.5. Inferencia Paramétrica

Seleccionar una función F en $\mathcal{F}$, a partir de los datos en la muestra, que constituya la descripción óptima del fenómeno de interés representa un reto formidable. Además de requerir un criterio de optimalidad, que en cualquier caso habría que proponer, la búsqueda del óptimo en un espacio de dimensión infinita dista de ser trivial. Una alternativa que reduce conceptual y cualitativamente esta dificultad, consiste en considerar, no el conjunto de todas las funciones de distribución, sino un subconjunto suficientemente grande como para que la descripción que se obtenga sea razonable, pero tal que la optimización se pueda llevar a cabo con herramientas matemáticas relativamente simples.

La idea es recurrir a una familia paramétrica $\mathcal{F}_\theta$ de modelos de probabilidad. En este caso, se considera que la función de distribución que interesa, $F(x)$, pertenece a un conjunto de la forma

$$\mathcal{F}_\theta = \{\, F(x) \mid F(x) = F(\, x\, ;\, \theta\,), \theta \in \Theta \,\}$$

donde, para cada valor de θ fijo, la distribución $F(\, x\, ;\, \theta\,)$ es totalmente conocida. θ se conoce como el parámetro de la familia y es un índice que identifica de manera inequívoca a cada elemento en $\mathcal{F}_\theta$.

I.5. Inferencia Paramétrica

En esta formulación, la determinación de la función de distribución óptima se reduce a la determinación del parámetro óptimo. Si el espacio paramétrico Θ es un subconjunto del espacio $\mathbb{R}^k$, con k fijo, el problema es uno de optimización en $\mathbb{R}^k$, que se puede abordar, una vez seleccionado el criterio de comparación, con los recursos habituales del calculo.

En la literatura es posible encontrar una variedad de familias paramétricas de funciones de distribución, que pueden utilizarse en el proceso de inferencia que aquí se discute. También es posible definir nuevas familias paramétricas con características que se consideren propicias para describir un tipo específico de datos. En todo caso, es importante insistir en que la elección de una familia paramétrica se produce con el objetivo de simplificar la tarea de describir el fenómeno de interés y necesariamente, implica el empleo de un modelo particular, con restricciones y limitantes que debe elegirse con cuidado.

Para seleccionar la familia paramétrica se considera la definición de la variable (¿Cuál es su soporte?, ¿Toma valores en un conjunto finito, numerable o potencialmente en un continuo?), el marco de referencia (¿La teoría o el conocimiento previo sugieren algún comportamiento particular de los datos, como simetrías?) y, por supuesto, el análisis estadístico de muestras preliminares o provenientes de estudios similares.

I.5. Inferencia Paramétrica

En lo que resta de este curso se partirá del supuesto de que la familia paramétrica $\mathcal{F}_\theta$ ya ha sido seleccionada y nos concentraremos en el problema remanente de producir inferencias sobre el valor del parámetro desconocido. Esta es el tema de que nos ocuparemos en los siguientes meses: La *Inferencia Estadística Paramétrica*.

El material que sigue tiene la estructura habitual de los libros de Inferencia Estadística Paramétrica y se desarrollará de acuerdo a una escuela de pensamiento estadístico particular cuyas bases se desarrollaron en los primeros treinta años del siglo XX.

Se trata de la escuela *Frecuentista* que debe su nombre a la interpretación que utiliza de la probabilidad. Es un enfoque muy exitoso y dominó por completo el panorama estadístico por mas de 50 años. Sigue siendo uno de los dos paradigmas mas importantes en la Estadística si bien ahora comparte el escenario con el Análisis Estadístico Bayesiano que se revisa en otro curso.

I.5. Inferencia Paramétrica

En cualquier caso, las ideas, conceptos, técnicas y métodos que se revisarán en el resto del curso tienen, como ya se ha indicado, el propósito de revisar el tema de la inferencia sobre el parámetro θ. Si se tiene una buena idea (aproximada) del valor del parámetro del modelo, se tendrá una idea (aproximada también) de la función de distribución de la variable que dio origen a los datos. En términos de inferencia interesa, en particular, proveer respuestas a las siguientes preguntas:

1. ¿Cuál es el valor de θ?
2. ¿Por dónde se localiza el parámetro θ?
3. Dada una idea preconcebida sobre θ,
   ¿Los datos son compatibles con ella?

Para dar respuesta a la primera pregunta, nos ocuparemos de las técnicas de *Estimación Puntual*; para la segunda recurriremos a las técnicas de *Estimación por Regiones* y la tercera la abordaremos en el apartado de *Contraste o Prueba de Hipótesis*. Iniciaremos con el apartado de Estimación Puntual.