II.2. El Error de Estimación

El tema es que el número e no se puede calcular pero la variable aleatoria ε se puede describir a través de su función de distribución. En el ejemplo,

$$T\left(\underline{X}_{(n)}\right) = \frac{1}{n}\Sigma_{i=1}^{n} X_i$$

donde $X_1, X_2, \ldots, X_n$ son variables aleatorias independientes, idénticamente distribuidas, según un modelo $N(\mu, \sigma^2)$. En consecuencia,

$$\hat{\mu}\left(\underline{X}_{(n)}\right) \sim N\left(\mu, \frac{\sigma^2}{n}\right).$$

Por lo tanto,

$$\varepsilon \sim N\left(0, \frac{\sigma^2}{n}\right).$$

II.2. El Error de Estimación

La característica más sorprendente de la distribución

$$\varepsilon \sim N\left(0, \frac{\sigma^2}{n}\right)$$

es que es *totalmente conocida*. Esto significa que aun cuando no se pueda calcular la realización particular e, si es posible calcular, por ejemplo, la probabilidad de que una realización cualquiera del error de estimación ε exceda, en valor absoluto, una cantidad, digamos c (dadas las unidades de X y, por tanto de μ, en el ejemplo c se mide en metros). Así, tenemos que la probabilidad de que la estimación falle por mas de c metros, está dada por:

$$P(\ |\varepsilon|\ >\ c\ ) = 1\ - P\ (\ |\varepsilon|\ \leq\ \ c\ )$$

$$= 1 - P(\ -c\ \leq\ \varepsilon\ \leq\ c\ )$$

$$= 1 - P(\ -\tfrac{\sqrt{n}}{\sigma}c\ \leq \tfrac{\sqrt{n}}{\sigma}\varepsilon\ \leq \tfrac{\sqrt{n}}{\sigma}c\ )$$

II.2. El Error de Estimación

En consecuencia,

$$P(\ |\varepsilon|\ >\ c\ ) = 1 - P(\ -\frac{\sqrt{n}}{\sigma}c\ \leq Z\ \leq \frac{\sqrt{n}}{\sigma}c\ )$$

con Z una variable *Normal Estándar*. En consecuencia, si $q = P(\ |\varepsilon|\ >\ c\ )$ se tiene la gráfica:

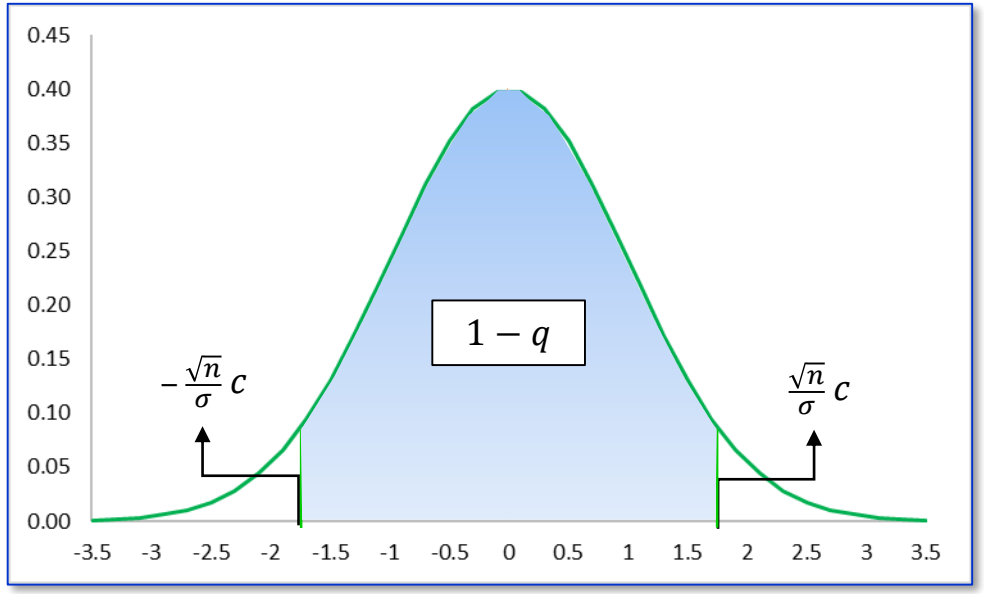

II.2. El Error de Estimación

De esta forma,

$$P(\ |\varepsilon|\ >\ c\ ) = 1 - (1 - 2P\left(\ Z\ \leq -\ \frac{\sqrt{n}}{\sigma}c\ \right))$$

$$= 2P(\ Z\ \leq -\ \frac{\sqrt{n}}{\sigma}c\ )$$

$$= 2\Phi\left(-\ \frac{\sqrt{n}}{\sigma}c\ \right).$$

En el ejemplo, se tiene $n = 10$ y $\sigma = 0.1$, de modo que $\frac{\sqrt{n}}{\sigma} = 31.62$ y en consecuencia,

$$q = 2\Phi(\ -31.62\ \ c\ ).$$

De esta expresión se sigue que la relación entre c y q es inversa. Es decir, a mayor margen de error c, corresponde una menor probabilidad q de producir una estimación que rebase ese límite.

II.2. El Error de Estimación

Con la Tabla, y la Gráfica que le acompaña, se puede visualizar la relación entre c y q.

c	q
0.0100	0.7519
0.0150	0.6353
0.0200	0.5271
0.0250	0.4292
0.0300	0.3428
0.0350	0.2684
0.0400	0.2059
0.0450	0.1548
0.0500	0.1139
0.0550	0.0820
0.0600	0.0578
0.0650	0.0399
0.0700	0.0269
0.0750	0.0177
0.0800	0.0114
0.0850	0.0072
0.0900	0.0044
0.0950	0.0027
0.1000	0.0016
0.1050	0.0009
0.1100	0.0005

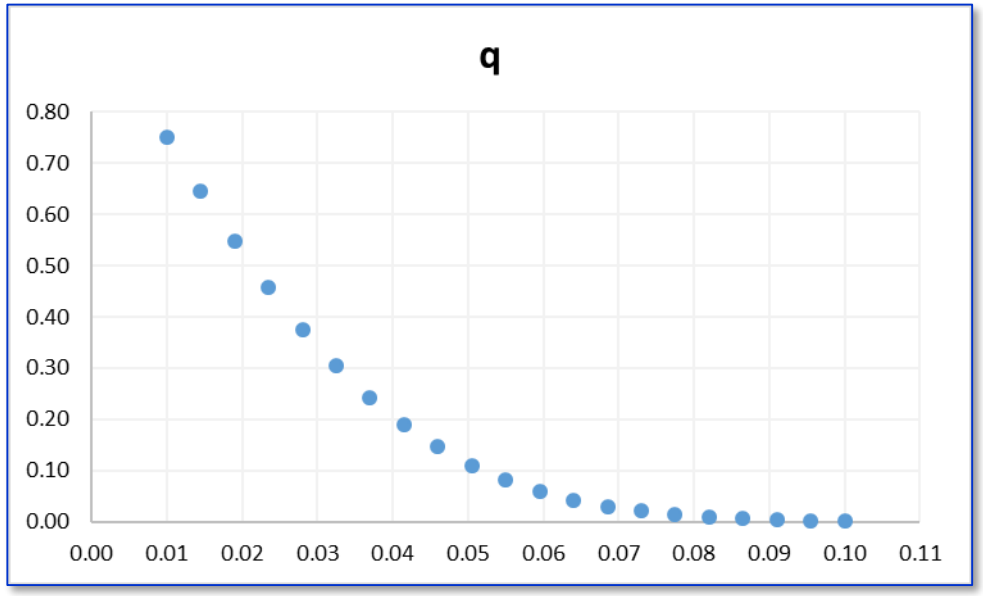

Figura. *Relación de q con c.*

II.2. El Error de Estimación

Así se tiene que, en este caso, el mecanismo produce valores estimados de la media poblacional de las estaturas μ que, por ejemplo, difieren del valor verdadero:

a) En más de 8 cms., un 1.1% de las veces.

b) En más de 5 cms., un 11.4% de las veces.

c) En más de 3 cms., un 34.3% de las veces.

d) En más de 1 cm., un 75.2% de las veces.

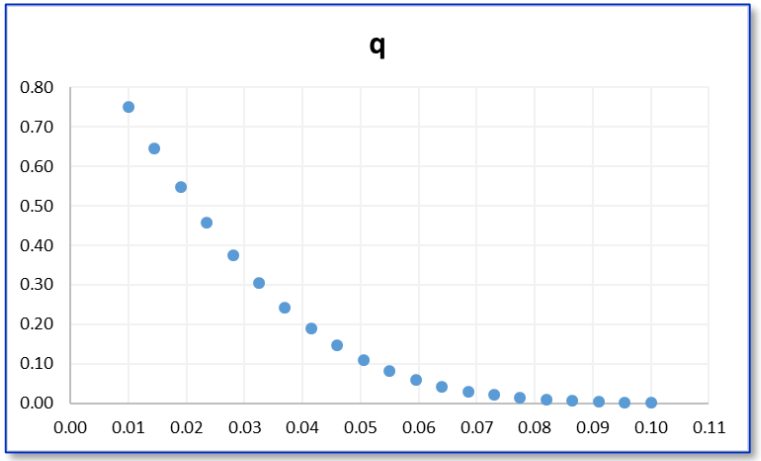

Tarea. *Escriba un reporte técnico donde analice la relación que guarda la probabilidad*

$$q = P(\ |\varepsilon|\ >\ c\ )$$

con las tres magnitudes c, n y σ.

II.3. Definiciones y Conceptos Básicos

Los resultados que hemos obtenido en el ejemplo dan lugar a algunas definiciones que se aplican al problema en su versión general:

Sea $\underline{X}_{(n)}$ una m.a. de una v.a. X con f.d.p.g. $f(x;\ \theta)$, de forma conocida. Utilice esta información para ***estimar*** *el valor del parámetro θ.*

Definición 2.1. *Una estadística* es una función de la muestra aleatoria $\underline{X}_{(n)}$ que toma valores en $\mathbb{R}^k$ para algún entero positivo k y cuya regla de correspondencia no involucra cantidades desconocidas.

Definición 2.2. *Un estimador* o función estimadora es una estadística que toma valores en el espacio paramétrico de θ.

II.3. Definiciones y Conceptos Básicos

Definición 2.3. A la función de distribución de una variable aleatoria que se obtiene como función de la muestra aleatoria $\underline{X}_{(n)}$ se le llama *distribución muestral*.

Definición 2.4. Al valor observado de un estimador se le denomina *valor estimado*.

Definición 2.5. A una variable aleatoria que se calcula como la diferencia entre un estimador y el parámetro que estima, se llama *error de estimación*.

No está de más insistir en que el error de estimación es, por construcción, una variable aleatoria *no observable.* Sin embargo, como se sigue del análisis previo, aun sin ser observable, puede ofrecer información muy valiosa sobre un estimador y su calidad como aproximación de un parámetro.

II.3. Definiciones y Conceptos Básicos

En el ejemplo, se tiene que:

- ✓ $T(\underline{X}_{(n)}) = \overline{X}$ es una *estadística*
- ✓ $T(\underline{X}_{(n)}) = \hat{\mu}\left(\underline{X}_{(n)}\right) = \overline{X}$ también es un *estimador* (de μ)
- ✓ La *distribución muestral* de $\overline{X}$ es una $N\left(\mu, \frac{\sigma^2}{n}\right)$
- ✓ $T(\underline{x}_{(n)}) = \overline{x}$ es un *valor estimado* (de μ)
- ✓ $\varepsilon = \hat{\mu}\left(\underline{X}_{(n)}\right) - \mu$ es *función de la muestra* $\underline{X}_{(n)}$ pero no es una estadística.
- ✓ La *distribución muestral* de ε es una $N\left(0, \frac{\sigma^2}{n}\right)$

II.3. Definiciones y Conceptos Básicos

Existen otras dos características que se presentan en este ejemplo particular y que vale la pena destacar y generalizar. En primer lugar, se tiene que $E(\overline{X}) = \mu$.

Este resultado significa que el estimador $\hat{\mu}(\underline{X}_{(n)}) = \overline{X}$ produce valores estimados *en torno* al valor del parámetro μ. Es decir, sus valores estimados *no sobreestiman* sistemáticamente a μ y *tampoco lo subestiman* sistemáticamente. De hecho, el promedio de todos los valores estimados posibles coincide con μ. Esta propiedad conduce a las siguientes definiciones de aplicación general.

Definición 2.6. Sea $\hat{\theta}(\underline{X}_{(n)})$ un estimador del parámetro θ. Se dice que $\hat{\theta}$ es *insesgado para θ* si se tiene que $E(\hat{\theta}) = \theta$, sea cual sea el valor del parámetro θ.

Definición 2.7. Sea $\hat{\theta}(\underline{X}_{(n)})$ un estimador del parámetro θ. El sesgo de $\hat{\theta}$ se define como la diferencia $Sesgo(\hat{\theta}) = E(\hat{\theta}) - \theta$.

Como consecuencia de estas definiciones, tenemos que todo estimador insesgado tiene sesgo cero.

II.3. Definiciones y Conceptos Básicos

De un estimador que tiene un sesgo positivo, se dice que *sobreestima* (en promedio) al correspondiente parámetro desconocido. En forma similar, si el sesgo es negativo se dice que el estimador *subestima* (en promedio) al parámetro desconocido.

El insesgamiento es un primer criterio que aparece en la literatura para comparar estimadores de manera que, en principio, son preferibles los estimadores insesgados sobre los sesgados. Por otra parte, es importante tener presente que la propiedad de insesgamiento no implica que los valores estimados correspondientes se encuentren cerca del valor del parámetro desconocido. Sólo que se encuentran alrededor del valor del parámetro. En este sentido, es relevante la segunda característica que se observa en el ejemplo. Ahí, se tiene que

$$Var\left(\overline{X}\right) = \sigma^2/n.$$

Esto significa, de acuerdo a la definición del operador varianza, y tomando en cuenta que el estimador es insesgado, que

$$E\{\left(\hat{\mu}\left(\underline{X}_{(n)}\right) - \mu\right)^2\} = \sigma^2/n.$$

II.3. Definiciones y Conceptos Básicos

Esta expresión se puede leer de la siguiente manera: *'El valor esperado del cuadrado del error de estimación de $\hat{\mu}$, es igual a σ^2/n'* y esta sí, provee información de cuan cerca pueden estar los valores estimados que se obtengan con este procedimiento, del valor del parámetro que estiman. La idea da lugar a otra definición.

Definición 2.8. Sea $\hat{\theta}(\underline{X}_{(n)})$ un estimador del parámetro θ. El *Error Cuadrático Medio* de $\hat{\theta}$, $ECM(\hat{\theta})$, se define como

$$ECM(\hat{\theta}) = E\{(\hat{\theta} - \theta)^2\}.$$

Naturalmente, un ECM menor es indicativo de una mayor concentración de los valores estimados respecto al valor del parámetro que se estima y, en ese sentido, entre dos estimadores posibles de un mismo parámetro, es preferible el que presente el ECM mínimo.

Un resultado que se sigue directamente de la definición es que si $\hat{\theta}$ es un estimador insesgado de θ, entonces $ECM(\hat{\theta}) = Var(\hat{\theta})$.

II.3. Definiciones y Conceptos Básicos

Esta relación no es cierta si el estimador no es insesgado pero se puede generalizar fácilmente. Suponga que $\hat{\theta}$ es un estimador de θ no necesariamente insesgado. Entonces,

$$
\begin{aligned}
ECM(\hat{\theta}) &= E\{\,(\hat{\theta}-\theta)^2\} \\
&= E\{\,(\hat{\theta}-E(\hat{\theta})+E(\hat{\theta})-\theta)^2\} \\
&= E\{\,(\,[\hat{\theta}-E(\hat{\theta})]+[E(\hat{\theta})-\theta]\,)^2\} \\
&= E\{\,(\,\hat{\theta}-E(\hat{\theta}))^2\}+2E\{(\hat{\theta}-E(\hat{\theta}))(E(\hat{\theta})-\theta)\}+\ E\{(E(\hat{\theta})-\theta)^2\} \\
&= E\{\,(\,\hat{\theta}-E(\hat{\theta}))^2\}+(E(\hat{\theta})-\theta\,)^2 \\
&= Var(\hat{\theta})+(Sesgo(\hat{\theta}))^2
\end{aligned}
$$

II.3. Definiciones y Conceptos Básicos

En resumen. tenemos

$$ECM(\hat{\theta}) = Var(\hat{\theta}) + (Sesgo(\hat{\theta}))^2.$$

De esta manera, para que el ECM sea pequeño es conveniente que tanto la varianza del estimador como su sesgo lo sean. En particular, si un estimador es insesgado, lo que importa es que su varianza sea la menor posible. En todo caso, el ECM permite comparar estimadores sin importar que unos sean insesgados y otros no lo sean.

De hecho, si basados en la misma muestra aleatoria $\underline{X}_{(n)}$ se cuenta con dos estimadores $\hat{\theta}_1$ y $\hat{\theta}_2$ del parámetro θ, y resulta que el primero es insesgado y el segundo no, puede ocurrir que el estimador sesgado $\hat{\theta}_2$ tenga una varianza tan pequeña que aun sumada al cuadrado de su sesgo, resulte menor a la varianza de $\hat{\theta}_1$.

En este sentido, es de utilidad examinar los siguientes diagramas.

II.3. Definiciones y Conceptos Básicos

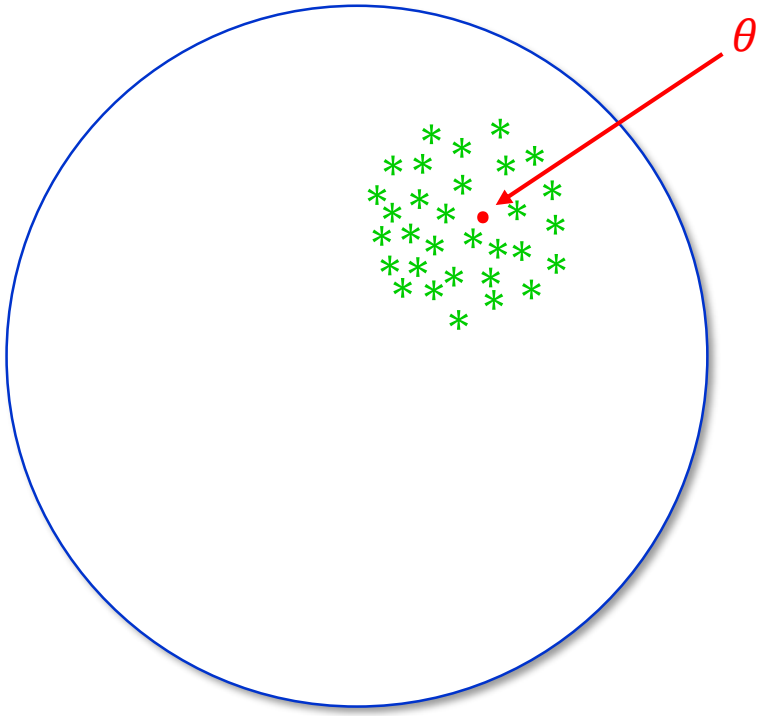

Figura. *Estimador insesgado con varianza menor*

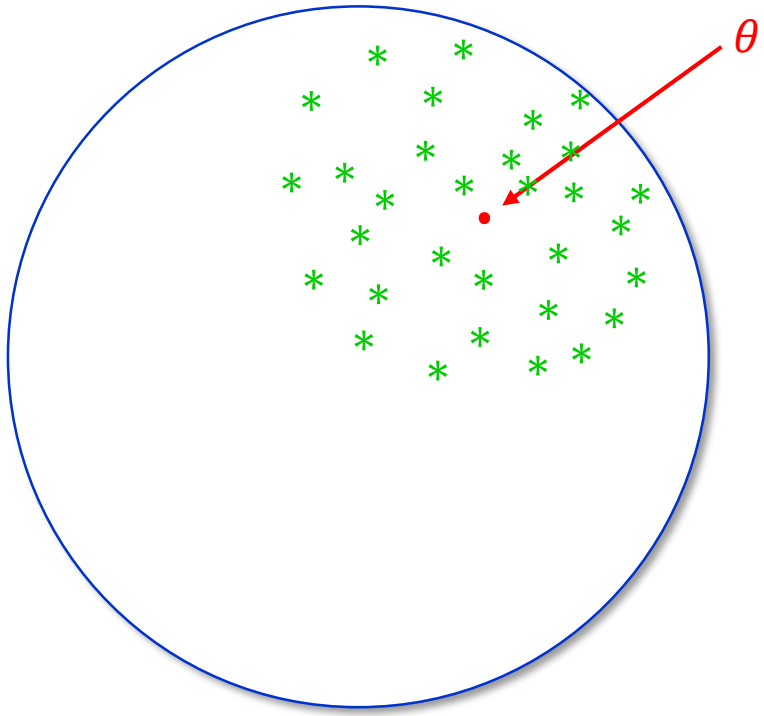

Figura. *Estimador insesgado con varianza mayor*

II.3. Definiciones y Conceptos Básicos

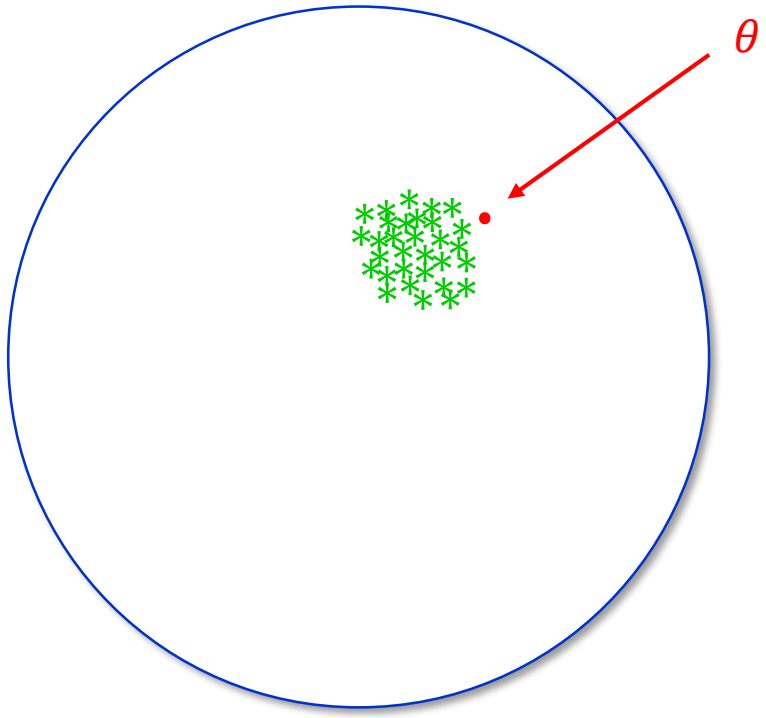

Figura. *Estimador Sesgado con varianza menor*

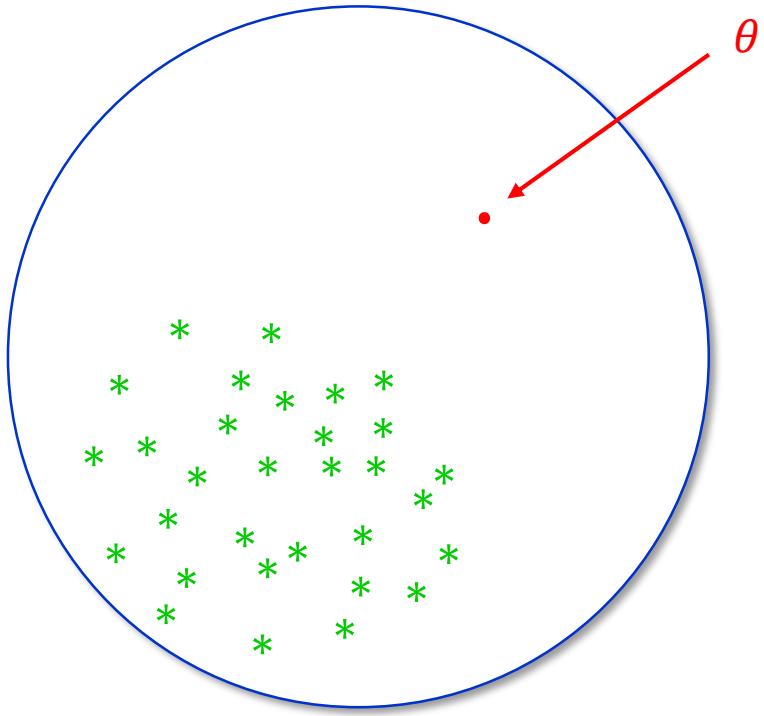

Figura. *Estimador Sesgado con varianza mayor*

II.3. Definiciones y Conceptos Básicos

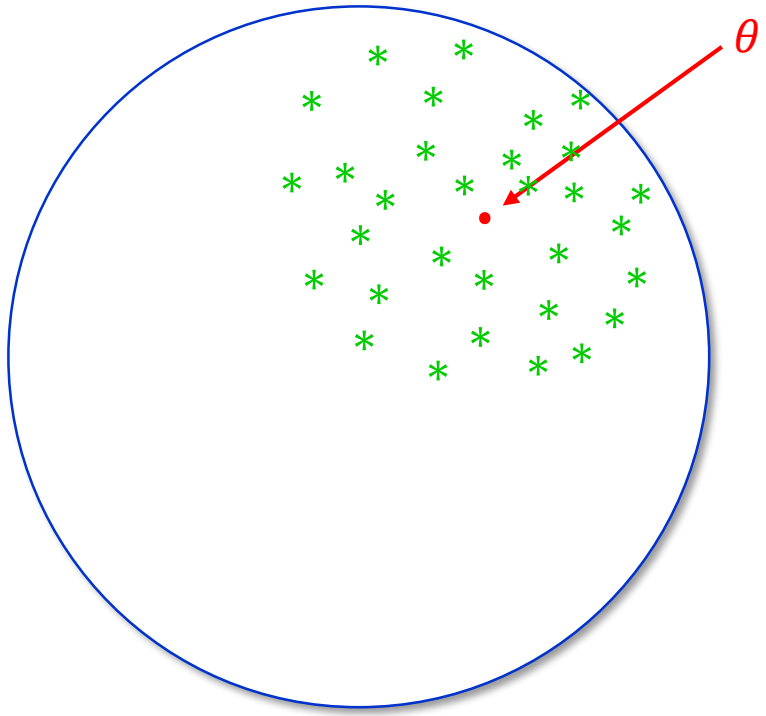

Figura. *Estimador insesgado con varianza mayor*

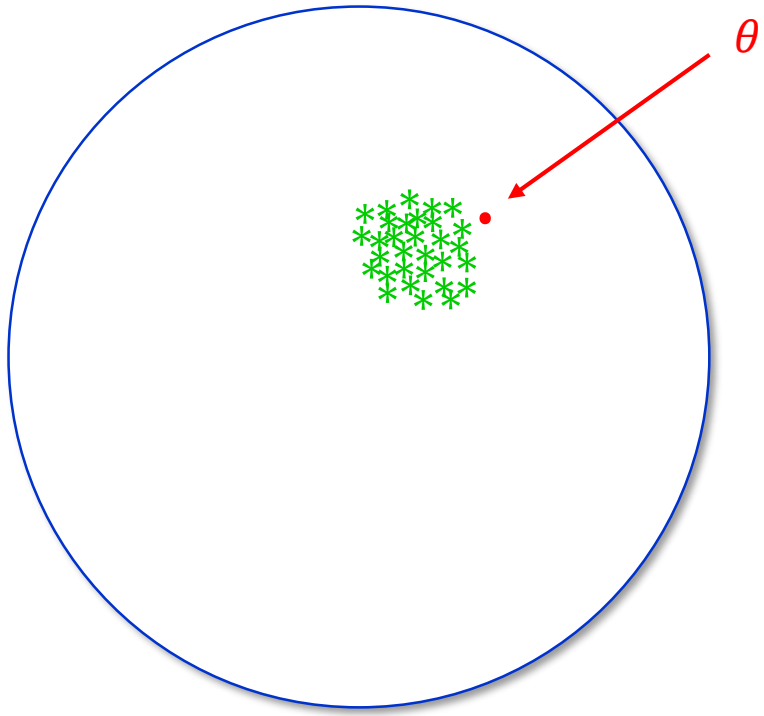

Figura. *Estimador Sesgado con varianza menor*

II.3. Definiciones y Conceptos Básicos

En resumen, si bien en muchos casos la propiedad de insesgamiento es importante, en general es preferible un estimador que minimice el ECM sin importar si es insesgado o no.

Finalmente, y también a partir del ejemplo, recordando que $\hat{\mu}\left(\underline{X}_{(n)}\right) = \overline{X}$, volvamos a la expresión

$$ECM(\hat{\mu}) \ = \sigma^2/n.$$

Puesto que el ECM mide la calidad del estimador, debe reconocerse que la calidad de $\overline{X}$, como estimador de μ, depende de la varianza de las observaciones σ^2, y del tamaño de la muestra n. El ECM aumenta con la varianza, pero disminuye con el tamaño de la muestra. Respecto a n, al aumentar el tamaño de la muestra multiplicándolo por un factor k el ECM disminuye como si los datos tuvieran una varianza menor, igual a la original dividida por k.

Este comportamiento, un menor ECM cuando aumenta n, corresponde con la idea intuitiva (que no satisfacen todos los estimadores) de que si la muestra crece de tamaño, para parecerse a la población completa, la descripción que se obtiene *deja de ser aproximada para convertirse en exacta.* En términos formales se dice que el estimador es *consistente.*