II.3. Definiciones y Conceptos Básicos

Es conveniente introducir una definición formal de esta idea.

Definición 2.9. *Sea $\underline{X}_{(n)}$ una m.a. de una v.a. X con f.d.p.g. $f(x;\ \theta)$, de forma conocida. Si $\hat{\theta}$ es un estimador de θ, se dice que $\hat{\theta}$ es un estimador* ***consistente en error cuadrático medio****, si satisface la condición*

$$ECM(\hat{\theta}) \longrightarrow 0 \text{ cuando } n \longrightarrow \infty.$$

Con esta definición se van perfilando los criterios que habrán de permitir la comparación entre estimadores alternativos y, en su caso, la determinación de estimadores óptimos.

En ocasiones interesan los estimadores insesgados; De entre ellos interesan, aún más, los de varianza pequeña. Más en general, interesan los estimadores con el menor ECM, especialmente si además son consistentes en ECM.

Consideremos ahora otro ejemplo. También con una variable aleatoria $Normal$, con solo un parámetro desconocido. En este caso, la varianza.

II.4. Ejemplos

***Ejemplo 2**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\ \mu,\ \sigma^2\ )$, donde la media μ es un valor conocido en los reales pero la varianza σ^2 es desconocida. Utilice la información en la muestra para estimar puntualmente el valor de σ^2.*

De nuevo, a partir del concepto de *analogía*, y tomando en cuenta que el parámetro por estimar es σ^2, la varianza poblacional, de inmediato aparece como un estimador posible la varianza muestral

$$\hat{\sigma}_1^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \overline{x})^2.$$

Recordemos, sin embargo, que a nivel poblacional, la definición de la varianza establece que

$$\sigma^2 = E\{(X - \mu)^2\}.$$

Entonces, si en el caso de μ la analogía consistía en aproximar el valor esperado poblacional con un promedio muestral, y considerando que ahora μ es conocido, la aproximación por analogía, con un del valor esperado que interviene en la varianza poblacional, conduce al estimador alternativo

$$\hat{\sigma}_2^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2.$$

II.4. Ejemplos

Como ventaja sobre el primer estimador se tiene que $\overline{x}$ es, como sabemos, un valor estimado de μ que en este caso no es necesario porque la media poblacional es conocida. Utilizar una estimación en lugar del valor verdadero de μ, podría implicar un mayor error de estimación.

En cualquier forma, si consideramos el estimador $\hat{\sigma}_2^2 = \frac{1}{n}\Sigma_{i=1}^{n}(X_i - \mu)^2$ es conveniente proceder con orden a determinar sus propiedades.

1. *Comprobar que es una estadística.*

2. *Establecer su función de distribución muestral.*

3. *Verificar si es insesgado y calcular su ECM.*

4. *Derivar la distribución muestral del error de estimación y evaluar la probabilidad de obtener errores superiores a un margen tolerable*.

II.4. Ejemplos

1. En este caso, $\hat{\sigma}_2^2$ es una función de la muestra $\underline{X}_{(n)}$ y si bien involucra al parámetro μ, no depende de cantidades desconocidas puesto que μ es conocido. Por tanto, *sí es una estadística.*

2. En cuanto a su distribución muestral, observe que $X_1, X_2, \dots, X_n$ son variables aleatorias independientes idénticamente distribuidas $N(\mu, \sigma^2)$. En consecuencia, si se define

$$Z_i = \frac{X_i - \mu}{\sigma}; \;\; i = 1, \dots, n$$

se tiene que $Z_1, Z_2, \dots, Z_n$ son variables aleatorias i.i.d. $N(0, 1)$. De la misma forma, si se define

$$U_i = Z_i^2 \; ; \;\; i = 1, \dots, n$$

entonces, $U_1, U_2, \dots, U_n$ son variables aleatorias i.i.d. $\mathcal{X}_{(1)}^2$ (ji cuadrada con un grado de libertad)

II.4. Ejemplos

Como consecuencia, resulta que

$$U = \Sigma_{i=1}^{n} U_i \sim \mathcal{X}_{(n)}^2.$$

Ahora bien, de la definición del estimador $\hat{\sigma}_2^2$, se puede comprobar que

$$\hat{\sigma}_2^2 = \frac{\sigma^2}{n} U.$$

Finalmente, en virtud de esta relación, *la distribución muestral del estimador es la un múltiplo de una variable $\mathcal{X}_{(n)}^2$ donde el múltiplo es la constante σ^2/n.* Es interesante observar que si bien la distribución de U ($\mathcal{X}_{(n)}^2$) es totalmente conocida, la distribución del estimador no es conocida por completo. Esto ocurre porque el múltiplo depende de σ^2 que no solamente es desconocida sino que precisamente es el parámetro que se está estimando.

II.4. Ejemplos

Es conveniente discutir este resultado en el caso general de un estimador $\hat{\theta}$ que se propone para aproximar el valor del parámetro θ. Si $\hat{\theta}$ es un estimador mínimamente aceptable, no puede tener una distribución totalmente conocida. De hecho, su distribución muestral debe depender del valor desconocido de θ. De no ser así, los valores estimados producidos por $\hat{\theta}$ no tendrían nada que ver con el parámetro que estiman.

3. En lo que respecta al sesgo y el ECM de $\hat{\sigma}_2^2$, tenemos que

$$E(\hat{\sigma}_2^2) = \frac{\sigma^2}{n} E(U),$$

ahora bien, $U \sim \mathcal{X}_{(n)}^2$, de manera que $E(U) = n$ (y $Var(U) = 2n$), entonces

$$E(\hat{\sigma}_2^2) = \sigma^2,$$

por lo que $\hat{\sigma}_2^2$ *es un estimador insesgado*.

II.4. Ejemplos

En cuanto al Error Cuadrático Medio, por tratarse de un estimador insesgado, resulta que

$$ECM(\hat{\sigma}_2^2) = Var(\hat{\sigma}_2^2)$$

$$= Var\left(\frac{\sigma^2}{n}\ U\right)$$

$$= \left(\frac{\sigma^2}{n}\right)^2 2n.$$

De manera que,

$$ECM(\hat{\sigma}_2^2) = \frac{2\sigma^4}{n}$$

y entonces, $\hat{\sigma}_2^2$ es un estimador consistente en ECM.

II.4. Ejemplos

4. Si, para determinar la distribución muestral del error muestral ε asociado a $\hat{\sigma}_2^2$, se define

$$\varepsilon = \hat{\sigma}_2^2 - \sigma^2,$$

se puede observar fácilmente que

$$\varepsilon = \sigma^2 \left(\frac{U}{n} - 1 \right).$$

De esta expresión se puede concluir, inmediatamente, que la distribución muestral de ε no es totalmente conocida. Este inconveniente, sin embargo, puede evitarse definiendo, en forma alternativa, el *error relativo de estimación*:

$$\varepsilon_* = \frac{\hat{\sigma}_2^2 - \sigma^2}{\sigma^2}.$$

II.4. Ejemplos

Para este otro error de estimación se tiene que

$$\varepsilon_* = \left(\frac{U}{n} - 1\right),$$

así que *la distribución muestral de ε_* es totalmente conocida* y es posible, entonces calcular, entre otras, la probabilidad de que el error relativo supere un margen de tolerancia predeterminado.

Tarea. *Considerando un tamaño de muestra $n = 10$, calcule la probabilidad de que el error de estimación relativo ε_* sea, en valor absoluto, mayor que las constantes $.01$, $.05$ y $.10$. Explique como se interpreta cada una de esas probabilidades.*

Habiendo analizado las propiedades de $\hat{\sigma}_2^2$, podría persistir la curiosidad por saber que tan competitivo resulta este estimador, comparado con $\hat{\sigma}_1^2 = \Sigma_{i=1}^{n} (X_i - \overline{X})^2/n$. Si atendemos al listado de propiedades, es inmediato que $\hat{\sigma}_1^2$ es una estadística.

II.4. Ejemplos

En cuanto al resto de la propiedades, su verificación se simplifica si primero se determina la correspondiente distribución muestral. Entonces, es interesante desarrollar la siguiente expresión:

$$\Sigma_{i=1}^{n}(X_i-\mu)^2 = \Sigma_{i=1}^{n}(X_i-\overline{X}+\overline{X}-\mu)^2.$$

$$= \Sigma_{i=1}^{n}\left((X_i-\overline{X})+\left(\overline{X}-\mu\right)\right)^2$$

$$= \Sigma_{i=1}^{n}(X_i-\overline{X})^2 + 2\,\Sigma_{i=1}^{n}\left(X_i-\overline{X}\right)\left(\overline{X}-\mu\right) + \Sigma_{i=1}^{n}\left(\overline{X}-\mu\right)^2$$

$$= \Sigma_{i=1}^{n}(X_i-\overline{X})^2 + 2\left(\overline{X}-\mu\right)\Sigma_{i=1}^{n}\left(X_i-\overline{X}\right) + n\,(\overline{X}-\mu)^2$$

$$= \Sigma_{i=1}^{n}(X_i-\overline{X})^2 + n\,(\overline{X}-\mu)^2.$$

II.4. Ejemplos

Como consecuencia, se tiene

$$\frac{\Sigma_{i=1}^{n}(X_i-\mu)^2}{\sigma^2} = \frac{\Sigma_{i=1}^{n}(X_i-\overline{X})^2}{\sigma^2} + \frac{n\,(\overline{X}-\mu)^2}{\sigma^2}$$

En términos de los estimadores, esta igualdad se puede expresar como

$$\frac{n\,\hat{\sigma}_2^2}{\sigma^2} = \frac{n\,\hat{\sigma}_1^2}{\sigma^2} + \frac{n\,(\overline{X}-\mu)^2}{\sigma^2}.$$

Ahora, recordando que

$$\hat{\sigma}_2^2 = \frac{\sigma^2}{n}\,U \quad \text{y} \quad \overline{X} \sim N\left(\mu, \frac{\sigma^2}{n}\right),$$

la identidad se puede escribir como

$$U = \frac{n\,\hat{\sigma}_1^2}{\sigma^2} + V \quad \text{con} \quad U \sim \mathcal{X}_{(n)}^2 \;\; \text{y} \;\; V \sim \mathcal{X}_{(1)}^2.$$

II.4. Ejemplos

Esta relación sugiere que la variable aleatoria $W = n\hat{\sigma}_1^2/\sigma^2$, podría tener una distribución $\mathcal{X}^2_{(n-1)}$, resultado que sería compatible con el resultado bien conocido que establece que si

$$V \sim \mathcal{X}^2_{(1)} \text{ y } W \sim \mathcal{X}^2_{(n-1)},$$

entonces $U = (W + V) \sim \mathcal{X}^2_{(n)}$ *si W y V son variables independientes*. Entonces, se puede empezar por explorar la eventual independencia entre

$$V = \frac{n\,(\overline{X}-\mu)^2}{\sigma^2} \quad \text{y} \quad W = \frac{\Sigma_{i=1}^{n}(X_i-\overline{X})^2}{\sigma^2}.$$

Lo primero, es observar que la aleatoriedad de V es debida a $\overline{X}$, una variable aleatoria $Normal$ mientras que la aleatoriedad de W proviene del conjunto de diferencias $X_i - \overline{X}$; $i = 1,..,n$ cada una de las cuales también tiene una distribución $Normal$.

II.4. Ejemplos

Tratándose de variables aleatorias $Normales$, para verificar si $X_i - \overline{X}$ es independiente de $\overline{X}$, basta con calcular la correspondiente covarianza. Procedamos

$$Cov\left(X_i - \overline{X}, \overline{X} \right) = Cov\left(X_i, \overline{X} \right) - Cov\left(\overline{X}, \overline{X} \right)$$

$$= Cov\left(X_i, \tfrac{1}{n} \Sigma_{j=1}^{n} X_j \right) - Var\left(\overline{X} \right)$$

Así que,

$$Cov\left(X_i - \overline{X}, \overline{X} \right) = \tfrac{1}{n} \Sigma_{j=1}^{n} Cov\left(X_i, X_j \right) - \frac{\sigma^2}{n}.$$

Ahora, recordando que las observaciones $X_1, X_2, \dots, X_n$ son independientes, se tiene que

$$Cov\left(X_i, X_j \right) = 0 \quad \forall\, i \neq j.$$

II.4. Ejemplos

En consecuencia, se tiene que

$$Cov\left(X_i - \overline{X}, \overline{X} \right) = \frac{1}{n} Var(X_i) - \frac{\sigma^2}{n}.$$

$$= \frac{1}{n}\sigma^2 - \frac{\sigma^2}{n}$$

$$= 0$$

De esta forma, queda establecido que cada diferencia de la forma $X_i - \overline{X}$ es independiente de $\overline{X}$. *Como consecuencia, el estimador de la media $\hat{\mu} = \overline{X}$, es independiente del estimador de la varianza $\hat{\sigma}_1^2 = \Sigma_{i=1}^{n} (X_i - \overline{X})^2/n$.* Más aún, en términos de la relación

$$U = W + V,$$

se tiene que V y W son variables aleatorias independientes.

II.4. Ejemplos

Entonces, tenemos la siguiente relación:

$$U = W + V$$

$$\mathcal{X}^2_{(n)} = \bigcirc + \mathcal{X}^2_{(1)}$$

independientes

Así, aumenta la evidencia en favor de que $W \sim \mathcal{X}^2_{(n-1)}$. Sin embargo, el resultado no ha sido probado formalmente. Para alcanzar ese objetivo, recuerde que la función generadora de momentos, cuando existe, caracteriza la distribución asociada. Además, *compruebe* que si Y es una variable aleatoria $\mathcal{X}^2_{(r)}$, su función generadora de momentos está dada por $M_Y(t) = (1-2t)^{-r/2}$.

II.4. Ejemplos

Con esta información, volvamos a la relación $U = W + V$ donde, para empezar, W y V son variables aleatorias independientes.

Ahora bien, por definición, si R es una variable aleatoria, la función generadora de momentos de R está dada por

$$M_R(t) = E\{e^{tR}\}$$

para todo valor $t \in \mathbb{R}$ tal que la esperanza exista. En ese caso,

$$\begin{aligned} M_U(t) &= E\{e^{tU}\} \\ &= E\left\{e^{t(W+V)}\right\} \\ &= E\{e^{tW+tV}\} \\ &= E\{e^{tW}\}E\{e^{tV}\}. \end{aligned}$$

II.4. Ejemplos

En consecuencia,

$$M_U(t) = M_W(t)\, M_V(t).$$

Ahora bien, $U \sim \mathcal{X}^2_{(n)}$ y $V \sim \mathcal{X}^2_{(1)}$, así que

$$M_U(t) = (1-2t)^{-n/2} \quad \text{y} \quad M_V(t) = (1-2t)^{-1/2}.$$

Sustituyendo, se tiene

$$(1-2t)^{-n/2} = M_W(t)\,(1-2t)^{-1/2}$$

de donde, necesariamente $M_W(t) = (1-2t)^{-(n-1)/2}$. Como conclusión, resulta que $W \sim \mathcal{X}^2_{(n-1)}$.

II.4. Ejemplos

La distribución $W \sim \mathcal{X}^2_{(n-1)}$, en términos del estimador $\hat{\sigma}_1^2 = \Sigma_{i=1}^n (X_i - \overline{X})^2/n$, significa que

$$\frac{n\,\hat{\sigma}_1^2}{\sigma^2} \sim \mathcal{X}^2_{(n-1)}$$

o, equivalentemente, que

$$\hat{\sigma}_1^2 = \frac{\sigma^2}{n}\,W$$

con W una variable aleatoria con distribución $\mathcal{X}^2_{(n-1)}$. Así, la estructura de esta distribución muestral es muy similar a la de $\hat{\sigma}_2^2$. En efecto,

$$\frac{n\,\hat{\sigma}_1^2}{\sigma^2} \sim \mathcal{X}^2_{(n-1)} \;;\quad \frac{n\,\hat{\sigma}_2^2}{\sigma^2} \sim \mathcal{X}^2_{(n)}.$$

En la literatura estadística se suele decir que en el caso de $\hat{\sigma}_1^2$ *se pierde un grado de libertad* debido a que, para calcularlo, *es necesario estimar primero el parámetro* μ.

II.4. Ejemplos

En cualquier caso, las propiedades generales de $\hat{\sigma}_1^2$ y $\hat{\sigma}_2^2$ son similares. Por lo que hace al punto tres del listado de propiedades (insesgamiento y ECM), utilizando el mismo procedimiento que se empleó con $\hat{\sigma}_2^2$, se tiene, en primer lugar que

$$E(\hat{\sigma}_1^2) = \left(\frac{n-1}{n}\right)\sigma^2.$$

Así, resulta que *$\hat{\sigma}_1^2$ no es un estimador insesgado de σ^2*. Más aún, su sesgo está dado por

$$\begin{aligned} Sesgo(\hat{\sigma}_1^2) &= \frac{n-1}{n}\sigma^2 - \sigma^2 \\ &= \left(\frac{n-1}{n} - 1\right)\sigma^2 \\ &= -\frac{\sigma^2}{n}. \end{aligned}$$

II.4. Ejemplos

De esta forma se tiene que el sesgo de $\hat{\sigma}_1^2$ es negativo y, por tanto, este estimador subestima en promedio al parámetro σ^2. También observamos que

$$lim_{n\longrightarrow\infty}\, Sesgo(\hat{\sigma}_1^2) = 0$$

de manera que el sesgo desaparece cuando el tamaño tiende a infinito. Esta característica también se puede definir en general.

Definición. *Sea $\underline{X}_{(n)}$ una m.a. de una v.a. X con f.d.p.g. $f(x;\,\theta)$, de forma conocida. Si $\hat{\theta}$ es un estimador sesgado de θ, se dice que $\hat{\theta}$ es* ***asintóticamente insesgado****, si satisface la condición*

$$Sesgo(\hat{\theta}) \longrightarrow 0 \text{ cuando } n \longrightarrow \infty.$$

En el ejemplo, se puede decir entonces que el estimador $\hat{\sigma}_1^2$ es sesgado pero *asintóticamente insesgado*. Veamos ahora que ocurre con el Error Cuadrático Medio de $\hat{\sigma}_1^2$.

II.4. Ejemplos

Para calcular el ECM es necesario determinar la varianza de $\hat{\sigma}_1^2$. Reproduciendo el análisis que se realizó para $\hat{\sigma}_2^2$, se observa que

$$Var(\hat{\sigma}_1^2) = \left(\frac{\sigma^2}{n}\right)^2 2(n-1),$$

de modo que simplificando, se tiene

$$Var(\hat{\sigma}_1^2) = \frac{2\sigma^4}{n}\left(\frac{n-1}{n}\right).$$

Ya en este punto se puede comprobar que si bien $\hat{\sigma}_1^2$ es sesgado mientras que $\hat{\sigma}_2^2$ es insesgado, la varianza de $\hat{\sigma}_1^2$ es menor que la varianza de $\hat{\sigma}_2^2$. En cualquier caso resta calcular el ECM de $\hat{\sigma}_1^2$. Con los resultados disponibles, tenemos

$$ECM(\hat{\sigma}_1^2) = \frac{2\sigma^4}{n}\left(\frac{n-1}{n}\right) + \left(-\frac{\sigma^2}{n}\right)^2$$

II.4. Ejemplos

Por tanto,

$$ECM(\hat{\sigma}_1^2) = \frac{2\sigma^4}{n^2}(n-1) + \frac{\sigma^4}{n^2}$$

$$= \frac{\sigma^4}{n^2}\{\, 2(n-1) + 1 \,\}$$

$$= \frac{\sigma^4}{n^2}\,(2n - 1).$$

Por lo pronto, podemos concluir que $\hat{\sigma}_1^2$ es un estimador de σ^2, consistente en ECM.

El último tema, por ahora, es comparar los Errores Cuadráticos Medios de $\hat{\sigma}_1^2$ y $\hat{\sigma}_2^2$ para un tamaño de muestra fijo n. Hasta ahora sabemos que

$$ECM(\hat{\sigma}_1^2) = \frac{\sigma^4}{n^2}\,(2n - 1) \quad \text{y} \quad ECM(\hat{\sigma}_2^2) = \frac{2\sigma^4}{n}.$$

II.4. Ejemplos

Para comparar los Errores Cuadráticos Mínimos, podemos ignorar el valor de σ^4 que es un factor común. Supongamos que el estimador insesgado $\hat{\sigma}_2^2$ tiene un ECM menor al de $\hat{\sigma}_1^2$. Entonces debe cumplirse que

$$\begin{aligned} & \frac{2}{n} < \frac{1}{n^2}(2n - 1) \\ \Longrightarrow \quad & \\ & 2\,n < 2n - 1 \end{aligned}$$

resultado que representa una contradicción. Por tanto, el análisis concluye que, en contra de la intuición inicial, $ECM(\hat{\sigma}_1^2) < ECM(\hat{\sigma}_2^2)$.

Este resultado demuestra que si se debe elegir un estimador para la varianza σ^2 en el modelo Normal, cuando la media μ es conocida, y las opciones disponibles son

$$\hat{\sigma}_1^2 = \tfrac{1}{n}\Sigma_{i=1}^{n}(x_i - \overline{x})^2 \quad \text{y} \quad \hat{\sigma}_2^2 = \tfrac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2$$

II.4. Ejemplos

Entonces, existen dos posibilidades:

1. Si la condición de insesgamiento se considera un requisito indispensable, el mejor estimador es $\hat{\sigma}_2^2$, que utiliza el valor conocido de μ y además es consistente.

2. Si no se impone la condición de insesgamiento, el estimador óptimo es $\hat{\sigma}_1^2$ que reemplaza a μ por la media muestral. Este estimador, si bien es sesgado, tiene ECM menor que $\hat{\sigma}_2^2$ y, también es consistente.

En cualquier caso, resta el análisis de la distribución muestral para el error de estimación asociado al estimador $\hat{\sigma}_1^2$.