II.4. Ejemplos

En este caso, podemos tomar ventaja del trabajo que se realizó en el caso de $\hat{\sigma}_2^2$. Si directamente nos referimos al error relativo, se tiene que

$$\varepsilon_* = \frac{\hat{\sigma}_1^2 - \sigma^2}{\sigma^2}.$$

Equivalentemente,

$$\varepsilon_* = \left(\frac{W}{n} - 1\right),$$

con W una variable aleatoria ahora con distribución $\mathcal{X}^2_{(n-1)}$. Por tanto, la distribución de ε_* es totalmente conocida y, de nuevo, es posible calcular la probabilidad

$$P(\,|\varepsilon_*| > c\,)$$

para cualquier nivel de tolerancia c.

II.4. Ejemplos

Consideremos ahora un tercer ejemplo.

Ejemplo 3. *Sea* $\underline{X}_{(n)}$ *una m.a. de una v. a.* X*, con distribución* $Unif(0,\theta)$*; es decir, uniforme continua en el intervalo* $(0,\theta)$*. Si* $\theta > 0$*, es un valor desconocido, utilice la información en la muestra para estimar puntualmente el valor de* θ*.*

Como todos sabemos, una distribución $Unif(0,\theta)$ tiene la siguiente función de densidad:

$$f(x;\theta) = \begin{cases} 0 & x \leq 0 \\ 1/\theta & 0 < x < \theta \\ 0 & x \geq \theta \end{cases}$$

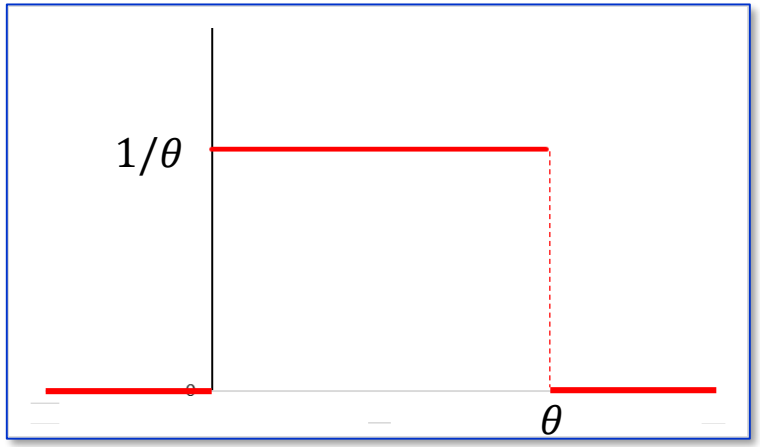

II.4. Ejemplos

Se trata de una familia paramétrica con tantos elementos como valores de θ existen en los reales positivos. Ahora bien, el parámetro θ, además de jugar el papel de un índice, puede interpretarse en términos de las propiedades de la variable aleatoria X. En particular, la interpretación posiblemente más simple se deriva del hecho de que $E(X) = \theta/2$, que implica la relación

$$\theta = 2E(X).$$

Aplicando la noción de analogía, aparece de inmediato un posible estimador:

$$\hat{\theta}_1 = 2\,\overline{X}.$$

Claramente, este estimador es una estadística y en cuanto a sus dos primeros momentos es fácil comprobar que

$$E\left(\hat{\theta}_1\right) = E(2\,\overline{X})$$

$$= 2E(\overline{X})$$

II.4. Ejemplos

$$E(\hat{\theta}_1) = 2E(\overline{X})$$

$$= 2E(\overline{X})$$

$$= 2E\left(\frac{1}{n}\Sigma_{i=1}^{n} X_i\right)$$

$$= 2\frac{1}{n}E(\Sigma_{i=1}^{n} X_i)$$

$$= 2\frac{1}{n}\Sigma_{i=1}^{n}E(X_i)$$

$$= 2\frac{1}{n}\Sigma_{i=1}^{n}\theta/2$$

$$= \theta$$

II.4. Ejemplos

En consecuencia, *$\hat{\theta}_1$ es un estimador insesgado de θ*. Recordando que si $X \sim Unif(0, \theta)$, entonces $Var(X) = \theta^2/12$, también podemos calcular la varianza (y el ECM) de este estimador.

$$
\begin{aligned}
Var(\hat{\theta}_1) &= Var(2\,\overline{X}) \\
&= 4\,Var(\overline{X}) \\
&= 4\,Var\left(\frac{1}{n}\Sigma_{i=1}^{n} X_i\right) \\
&= \frac{4}{n^2} Var(\Sigma_{i=1}^{n} X_i) \\
&= \frac{4}{n^2}\,\Sigma_{i=1}^{n} Var(\,X_i)
\end{aligned}
$$

II.4. Ejemplos

De esta forma, tenemos que

$$Var(\hat{\theta}_1) = \frac{4}{n^2}\, \Sigma_{i=1}^{n}\, \theta^2/12$$

$$= \frac{4\, n\, \theta^2}{12\, n^2}$$

$$= \frac{\theta^2}{3\, n}.$$

Así, $\hat{\theta}_1$ es un estimador insesgado de θ con $ECM(\hat{\theta}_1) = \theta^2/3n$, lo que resulta en un estimador consistente en Error Cuadrático Medio. El tema que resta para poder calcular probabilidades en relación con el error de estimación, es determinar la distribución muestral de $\hat{\theta}_1$. En ese sentido es conveniente recordar que

$$\hat{\theta}_1 = 2\, \overline{X}.$$

II.4. Ejemplos

Equivalentemente, podemos escribir

$$\hat{\theta}_1 = \left(\frac{2}{n}\right) \Sigma_{i=1}^{n} X_i \, .$$

Un resultado muy simple establece que $X \sim Unif(0, \theta)$ si y sólo si $X = \theta U$ con $U \sim Unif(0, 1)$. Haciendo uso de ese resultado podemos reescribir

$$\hat{\theta}_1 = \left(\frac{2\theta}{n}\right) \Sigma_{i=1}^{n} U_i,$$

con $U_1, U_2, \ldots, U_n$ variables aleatorias independientes con distribución $Unif(0, 1)$. Entonces, el estimador es un múltiplo de una variable aleatoria U que se define como la suma de n variables $Uniformes$ en $(0, 1)$ independientes. Naturalmente, la distribución muestral del estimador está determinada por la de U.

II.4. Ejemplos

El tema es que no es fácil determinar la distribución de la suma de un número arbitrario de variables aleatorias (independientes) $Unif(0,1)$.

Tarea. *Investigue cuál es, y como se puede utilizar para realizar cálculos de probabilidades, la función de distribución de la suma de n variables aleatorias independientes con distribución $Uniforme\ en\ (0,1)$.*

Contando con que se ocuparán de esta tarea, es interesante visualizar como ocurre una muestra aleatoria en este caso.

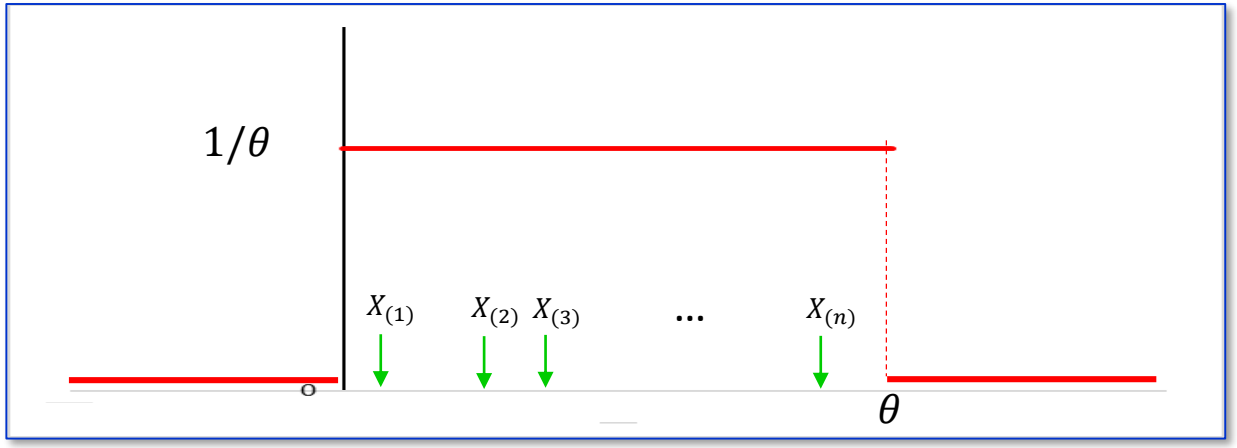

II.4. Ejemplos

En el diagrama $X_{(1)} < X_{(2)} < \cdots < X_{(n)}$ representan las estadísticas de orden de la muestra o, equivalentemente, la muestra ordenada. Un hecho resulta evidente del diagrama. De entre todas las estadísticas de orden, existe una que es la más próxima al parámetro θ. Se trata del máximo de la muestra, $X_{(n)}$. Este resultado sugiere, de inmediato, un estimador alternativo:

$$\hat{\theta}_2 = X_{(n)}.$$

Del propio diagrama (y de su definición) es claro que $\hat{\theta}_2$ no es insesgado. Sólo puede producir valores estimados por debajo del verdadero valor del parámetro. Por tanto, es sesgado y subestima a θ. Sin duda es una estadística y para determinar su esperanza y varianza es indispensable identificar su distribución muestral que, a diferencia de lo ocurrido con $\hat{\theta}_2$ es relativamente inmediata. En efecto, *verifique que si* $T\left(\underline{X}_{(n)}\right) = X_{(n)}$, *entonces*

$$f_T(t) = n\,[F_X(t)]^{n-1} f_X(t),$$

con $F_X(\cdot)$ *y* $f_X(\cdot)$ *las funciones de distribución y densidad respectivamente de* X.

II.4. Ejemplos

En este caso,

$$f_X(t) = \begin{cases} 0 & t \leq 0 \\ 1/\theta & 0 < t < \theta \\ 0 & t \geq \theta \end{cases} \quad ; \quad F_X(t) = \begin{cases} 0 & t \leq 0 \\ t/\theta & 0 < t < \theta \\ 1 & t \geq \theta \end{cases}$$

de modo que

$$f_T(t) = \begin{cases} 0 & t \leq 0 \\ n\,[t/\theta]^{n-1}(1/\theta) & 0 < t < \theta \\ 0 & t \geq \theta \end{cases}$$

Ahora es posible (y simple) el cálculo de los momentos de $X_{(n)}$.

II.4. Ejemplos

En efecto,

$$E\left(\hat{\theta}_2\right) = \int_0^{\theta} tn\,[t/\theta]^{n-1}(1/\theta)\,dt$$

$$= \int_0^{\theta} n\,[t/\theta]^{n}\,dt$$

$$= \frac{n}{n+1}\,\theta\left[\frac{t}{\theta}\right]^{n+1}\Bigg|_0^{\theta}$$

$$= \left(\frac{n}{n+1}\right)\theta.$$

II.4. Ejemplos

Además,

$$E\left(\hat{\theta}_2{}^2\right) = \int_0^{\theta} t^2\, n\, [t/\theta]^{n-1}(1/\theta)\, dt$$

$$= \int_0^{\theta} n\, \theta\, [t/\theta]^{n+1}\, dt$$

$$= \frac{n}{n+2}\, \theta^2 \left[\frac{t}{\theta}\right]^{n+1} \Bigg|_0^{\theta}$$

$$= \left(\frac{n}{n+2}\right) \theta^2.$$

II.4. Ejemplos

En consecuencia,

$$Var(\hat{\theta}_2) = \left(\frac{n}{n+2}\right)\theta^2 - \left(\frac{n}{n+1}\right)^2 \theta^2$$

$$= \theta^2\, n \left[\frac{1}{(n+1)^2\,(n+2)} \right]$$

$$= \frac{\theta^2\, n}{(n+1)^2\,(n+2)}\,.$$

Como consecuencia de estos resultados podemos confirmar, por un parte, que $\hat{\theta}_2$ es sesgado con

$$Sesgo\,(\hat{\theta}_2) = \left(\frac{n}{n+1}\right)\theta - \theta$$

$$= -\left(\frac{1}{n+1}\right)\theta.$$

II.4. Ejemplos

Así que *$\hat{\theta}_2$ subestima a θ pero es asintóticamente insesgado*. En cuanto a su ECM, tenemos que

$$ECM(\hat{\theta}_2) = \frac{\theta^2\, n}{(n+1)^2\,(n+2)} + \frac{\theta^2}{(n+1)^2}$$

$$= \frac{\theta^2}{(n+1)^2}\left[\frac{n}{(n+2)} + 1\right]$$

$$= \frac{\theta^2\, 2(n+1)}{(n+1)^2\,(n+2)}$$

$$= \frac{2\,\theta^2}{(n+1)\,(n+2)},$$

con lo que se comprueba que *$\hat{\theta}_2$ es consistente en ECM*.

II.4. Ejemplos

En cuanto a la comparación $\hat{\theta}_1$ entre y $\hat{\theta}_2$ tenemos que el primero es insesgado pero el segundo es sesgado. Por tanto,

$$ECM(\hat{\theta}_1) = Var(\hat{\theta}_1)$$

$$= \frac{\theta^2}{3\,n}\,.$$

Por otra parte, se comprobó que

$$ECM(\hat{\theta}_2) = \frac{2\,\theta^2}{(n+1)\,(n+2)}\,.$$

No es necesario un análisis muy profundo para reconocer que el ECM de $\hat{\theta}_1$ converge a cero más lentamente de lo que lo hace el ECM de $\hat{\theta}_2$. En efecto, el es de orden n^{-1} mientras que el segundo es de orden n^{-2}. En todo caso, es interesante verificar lo que ocurre para una n fija.

Tarea. *Compruebe que* $ECM(\hat{\theta}_2) = ECM(\hat{\theta}_1)$ *si* $n = 1$ *y que* $ECM(\hat{\theta}_2) < ECM(\hat{\theta}_1) \quad \forall\, n > 1.$

II.4. Ejemplos

Finalmente, y no es asunto menor, en el caso de $\hat{\theta}_2$ se cuenta con su distribución muestral, así que se puede abordar el estudio del error de estimación para determinar si es posible calcular las probabilidades de interés. Si se considera el error de estimación absoluto

$$\varepsilon = \hat{\theta}_2 - \theta,$$

es inmediato que la densidad de ε resulta:

$$f_\varepsilon(e) = \begin{cases} 0 & e \leq -\theta \\ n\,[\,e/\theta + 1]^{n-1}\,(1/\theta) & -\theta < e < 0 \\ 0 & e \geq 0 \end{cases}$$

que no es totalmente conocida en tanto que depende de θ. Este problema, sin embargo, se puede enfrentar exitosamente si, como en casos previos, se considera el error de estimación relativo:

$$\varepsilon_* = \frac{\hat{\theta}_2 - \theta}{\theta}.$$

II.4. Ejemplos

Efectivamente, si se toma en cuenta que

$$\varepsilon_* = \frac{\varepsilon}{\theta},$$

la densidad de ε_* se calcula muy fácilmente:

$$f_{\varepsilon_*}(e_*) = \begin{cases} 0 & e_* \leq -1 \\ n\,[\,e_* + 1]^{n-1} & -1 < e_* < 0 \\ 0 & e_* \geq 0 \end{cases}$$

y es completamente conocida. Así, es posible calcular la probabilidad

$$P(\,|\varepsilon_*| > c\,)$$

para cualquier constante c.

II.4. Ejemplos

Un tema adicional, que resulta de interés en este caso lo mismo que en algunos otros problemas en que se dispone de estimadores sesgados, es el siguiente. Ustedes comprobaron, como tarea, que $\hat{\theta}_2$ es un mejor estimador comparado con $\hat{\theta}_1$ en el sentido de ECM. Previamente habíamos comprobado que $\hat{\theta}_2$ es un estimador sesgado. De hecho,

$$E(\hat{\theta}_2) = \left(\frac{n}{n+1}\right)\theta \quad \text{y} \quad Var(\hat{\theta}_2) = \frac{\theta^2\, n}{(n+1)^2\,(n+2)}\,.$$

Pues bien, el tema del sesgo en este caso se puede eliminar si se define un tercer estimador

$$\hat{\theta}_3 = \left(\frac{n+1}{n}\right)\hat{\theta}_2$$

Para este estimador se tiene

$$E(\hat{\theta}_3) = \theta \quad \text{y} \quad Var(\hat{\theta}_3) = \frac{\theta^2}{n\,(n+2)}.$$

Tarea. *Compare la calidad de los estimadores $\hat{\theta}_2$ y $\hat{\theta}_3$.*

II.4. Ejemplos

Concluiremos esta sección con un ejemplo más que parece muy simple y que, sin embargo, ilustra algunas dificultades que no habían aparecido en ejemplos previos.

***Ejemplo 4**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Bernoulli(\theta)$ con $\theta \in (0,1)$ un valor desconocido. Utilice la información en la muestra para estimar puntualmente el valor de θ.*

Como en los casos anteriores θ, además de servir como índice de la familia paramétrica de modelos de probabilidad, tiene una interpretación (de hecho dos) que sugiere una función estimadora. En efecto, θ es la probabilidad de éxito en el modelo; es decir, $\theta = P(X = 1)$. Pero también es cierto que θ es la esperanza de X.

Si se interpreta como la media poblacional, se puede estimar con la media muestral. Por otra parte, dado que en el enfoque frecuentista, la probabilidad es el límite de las frecuencias relativas correspondientes, un estimador podría ser la proporción de éxitos en la muestra. El tema es que cualquiera de estas interpretaciones que se considere conduce al mismo estimador por *analogía:* la media muestral que coincide con la proporción muestral de éxitos.

II.4. Ejemplos

Así, tenemos el estimador $\hat{\theta} = \overline{X}$. Esta función estimadora ya la hemos considerado y sabemos que es una estadística. Además,

$$\hat{\theta} = \frac{1}{n} \ \Sigma_{i=1}^{n} X_i$$

$$= \frac{1}{n} \ Y$$

con $Y = \Sigma_{i=1}^{n} X_i$ una variable aleatoria con distribución $Binomial(\theta, n)$. De esta forma, tenemos que el estimador es el producto de una constante conocida por una variable aleatoria cuya distribución depende del parámetro θ. Como resultado podemos afirmar que, como era de esperar, la distribución muestral de $\hat{\theta}$ depende de θ. Ahora, en lo que respecta al insesgamiento,

$$E(\hat{\theta}) \ = \ E\left(\frac{1}{n} \ Y\right)$$

$$= \frac{1}{n} \ E(\ Y).$$

II.4. Ejemplos

pero Y es $Binomial(\theta, n)$. En consecuencia,

$$E(\hat{\theta}) = \frac{1}{n}\, n\, \theta$$

$$= \theta$$

Y se comprueba que *$\hat{\theta}$ es un estimador insesgado*. En cuanto a la varianza, que coincide con el error cuadrático medio el cálculo es igualmente simple; basta recordar que $Var(Y) = n\theta(1-\theta)$.

$$Var(\hat{\theta}) = Var\left(\frac{1}{n}\ Y\right)$$

$$= \frac{1}{n^2}\, Var(\, Y).$$

II.4. Ejemplos

Finamente,

$$Var(\hat{\theta}) \ = \ \frac{1}{n^2} n\theta(1-\theta)$$

$$= \ \frac{1}{n} \ \theta(1-\theta).$$

De esta manera queda establecido que $\hat{\theta}$ es un estimador insesgado de θ que además resulta consistente en error cuadrático medio. En lo concerniente al error de estimación, observe que si Y se distribuye $Binomial(\theta, n)$, entonces su soporte está dado por $\{0, 1, \dots, n\}$. Entonces, el soporte de $\hat{\theta}$ resulta

$$\left\{ \ 0, \frac{1}{n}, \frac{2}{n} \dots, 1 \ \right\}.$$

El hecho de que $\hat{\theta}$ sea un estimador discreto con este soporte es muy importante porque tanto el error de estimación ε como el error de estimación relativo ε_* e incluso cualquier otra forma del error de estimación implican una función $h(\cdot\,;\theta)$, que depende de θ y se aplica a $\hat{\theta}$ para medir cuan

II.4. Ejemplos

lejos se encuentra la estimación del valor verdadero del parámetro. De esta forma,

$$\varepsilon = h(\hat{\theta}\ ;\ \theta)$$

y, tratándose de una variable aleatoria discreta, sabemos que el soporte de ε está dado por

$$\left\{ h(0\ ;\ \theta), h\left(\frac{1}{n};\ \theta\right), h\left(\frac{2}{n};\ \theta\right) \ldots, h(1;\ \theta) \right\}$$

que está formado por valores que dependen del valor del parámetro θ. Este resultado implica que *la distribución muestral del error de estimación no puede ser conocida, no importa que versión del error se utilice.* En estas condiciones, no es posible evaluar la probabilidad de que el error de estimación sobrepase los márgenes de tolerancia previstos.

Volveremos mas adelante al tema para comprobar que este tipo de problemas se pueden resolver, habitualmente con aproximaciones asintóticas.