II.5. Estadísticas Suficientes

Existen otros criterios en la literatura estadística, además del insesgamiento, el error cuadrático medio y la consistencia, que pueden utilizarse para comparar estimadores. Aquí no ocuparemos de uno que es sumamente importante y que analiza si el estimador captura toda la información que la muestra contiene respecto al parámetro desconocido.

Como se ha discutido, cuando se determina la distribución muestral de un estimador, la primera condición que se debe verificar es que es a distribución dependa del parámetro que se estima. De esta manera, si $\hat{\theta}$ es un estimador del parámetro θ, y su función de densidad de probabilidad generalizada está dada por $f_{\hat{\theta}}(\cdot)$, es importante comprobar que, de hecho, esta función es de la forma $f_{\hat{\theta}}(\cdot\,;\theta)$ y, por tanto, depende del valor del parámetro.

La discusión de esta relación entre estimador y parámetro, de hecho, se puede abordar también para asegurar que la muestra $\underline{X}_{(n)}$ guarda relación con el parámetro de interés θ. En efecto, aun cuando pueda parecer obvio, es indispensable que los datos con los que se pretende producir las inferencias sobre θ guarden relación con ese parámetro.

II.5. Estadísticas Suficientes

Lo interesante es que esa condición inicial puede plasmarse de forma precisa en el proceso de modelado. Efectivamente, los datos son producto de la observación de la muestra aleatoria $\underline{X}_{(n)}$ cuya distribución se describe con la función de densidad de probabilidades generalizada

$$f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \; ; \; \theta \right).$$

Este modelo es el vínculo entre la muestra y el parámetro. Si el modelo no involucrase a θ, la muestra proveería información que no tiene nada que ver con el parámetro de interés. Es decir, si la densidad conjunta de la muestra fuese de la forma $f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \right)$ los datos no contendrían información útil respecto a θ.

Suponga ahora que $\underline{X}_{(n)}$ es una muestra con densidad $f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}; \theta \right)$. Es decir, sí contiene información sobre θ. Sea ahora $T(\underline{X}_{(n)})$ una estadística (como todos los estimadores). Por definición, T es una función de las variables aleatorias $\underline{X}_{(n)}$ y, por tanto, también es una variable aleatoria. Ahora bien, su distribución muestral puede, o no, depender de θ.

II.5. Estadísticas Suficientes

Si $f_T(\ t\ )$ no depende de θ, esta estadística no guarda relación con el parámetro; es una resumen de la información muestral que no provee información sobre θ y, desde luego, no es apta para ser considerada como un estimador de ese parámetro.

Si, alternativamente, la forma de su distribución es $f_T(t;\ \theta)$, esto significa que T está relacionada con θ. Es decir, constituye un resumen de la información muestral que sí guarda relación con el parámetro y podría considerarse en la producción de un estimador de θ.

Ahora bien, en este segundo escenario, T es un resumen de la información contenida en $\underline{X}_{(n)}$ que guarda relación con θ. La pregunta clave es: ¿Este resumen, captura toda lo información que contiene la muestra sobre θ?

Una respuesta, técnica y elegante a esta pregunta pasa por calcular la distribución condicional

$$f_{\underline{X}_{(n)|\ T=t}}\left(\ \underline{x}_{(n)}\ \right).$$

II.5. Estadísticas Suficientes

Este modelo de probabilidad condicional describe lo que se puede afirmar sobre la muestra $\underline{X}_{(n)}$, una vez que la estadística T ha sido observada. Si este modelo sigue involucrando a θ, como lo hacía el modelo marginal, no condicional, significa que aun a pesar de conocer la valor de la estadística, los datos aun conservan información sobre el parámetro. En el caso contrario, si el modelo condicional ya no involucra a θ, si es de la forma

$$f_{\underline{X}_{(n)|\,T=t}}\left(\,\underline{x}_{(n)}\,\right)$$

entonces, el comportamiento de la muestra, una vez que se observó T, ya no guarda relación con el parámetro, ya no contiene información sobre el parámetro.

La idea es que si originalmente la muestra estaba relacionada con θ, pero después de haber observado la estadística T (que es un resumen de la información en la muestra) esa muestra ya no guarda relación con θ, debe ser porque ***T extrajo toda la información que contenía la muestra sobre el parámetro.***

II.5. Estadísticas Suficientes

Esta noción fue propuesta y desarrollada, como algunas otras ideas fundamentales de la llamada Estadística Matemática, por *R.A. Fisher* hace un poco más de un siglo. La definición precisa, y general, es la siguiente.

Definición. *Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con f.d.p.g. $f_X(x;\,\theta)$. Sea además, $T(\underline{X}_{(n)})$ una estadística. Se dice que* ***T es suficiente para θ****, si la función de densidad conjunta condicional $f_{\underline{X}_{(n)|\,T=t}}\left(\underline{x}_{(n)}\right)$ no depende de θ.*

La suficiencia estadística es una propiedad que se esperaría que satisfagan los mejores estimadores. Representa una noción que, a diferencia del insesgamiento y el error cuadrático medio, no se basa en la idea de cercanía entre los valores que produce la estadística y el parámetro desconocido. La suficiencia tiene conexiones con las ideas de información y medidas de información, como se expondrá mas adelante.

Tarea. *Escriba una cuartilla con el resumen biográfico de R.A. Fisher e investigue en que año propuso el concepto de* ***suficiencia estadística****.*

II.6. Más Ejemplos

Volvamos a los ejemplos que hemos examinado con otros criterios, para ilustrar los alcances del concepto de suficiencia estadística.

***Ejemplo 4**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Bernoulli(\theta)$ con $\theta \in (0,1)$. Verifique si el estimador $\hat{\theta} = \overline{X}$ es una estadística suficiente para θ.*

La primera observación que vale la pena tener en cuenta es que, como ya se ha señalado, la estadística $\overline{X}$ toma valores en el conjunto $\{\ 0, 1/n, 2/n \dots, 1\ \}$ pero $\overline{X} = i/n$ si y sólo si $Y = i$ para $i = 0, 1, \dots, n$, con $Y = \Sigma_{i=1}^{n} X_i$. El punto relevante es que $T_1\left(\underline{X}_{(n)}\right) = \overline{X}$ es una función, uno a uno, totalmente conocida, de $T_2\left(\underline{X}_{(n)}\right) = Y$. Por tanto,

$$T_1\left(\underline{X}_{(n)}\right) = t_1 \quad \Leftrightarrow \quad T_2\left(\underline{X}_{(n)}\right) = t_2\ , \text{ con } t_2 = n\, t_1.$$

Como consecuencia,

$$f_{\underline{X}_{(n)|\,T_1=t_1}}\left(\underline{x}_{(n)}\right) = f_{\underline{X}_{(n)|\,T_2=t_2}}\left(\underline{x}_{(n)}\right).$$

II.6. Más Ejemplos

Esta identidad permite asegurar que la estadística $T_1\left(\underline{X}_{(n)}\right) = \overline{X}$ es suficiente para θ si y sólo si la estadística $T_2\left(\underline{X}_{(n)}\right) = \Sigma_{i=1}^{n} X_i$ es suficiente para θ. De hecho, este resultado particular se puede probar en un versión mucho mas general.

Teorema. *Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con f.d.p.g. $f_X(x;\ \theta)$. Sean $T_1(\underline{X}_{(n)})$ y $T_2(\underline{X}_{(n)})$ dos estadísticas tales que $T_2(\underline{X}_{(n)})$ depende de la muestra exclusivamente a través de $T_1\left(\underline{X}_{(n)}\right)$; es decir, existe una función $h(\cdot)$ tal que $T_2\left(\underline{X}_{(n)}\right) = h(T_1\left(\underline{X}_{(n)}\right))$. Entonces, si $T_2\left(\underline{X}_{(n)}\right)$ es suficiente para θ, $T_1\left(\underline{X}_{(n)}\right)$ también es suficiente para θ.*

En el ejemplo, para verificar si $T_1 = \overline{X}$ es suficiente para θ, basta con verificarlo para $T_2 = \Sigma_{i=1}^{n} X_i$. Así, es necesario calcular la probabilidad condicional de que la muestra $\underline{X}_{(n)}$ resulte en la muestra observada $\underline{x}_{(n)}$, dado que la suma $\Sigma_{i=1}^{n} X_i$ toma el valor t.

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, \Sigma_{i=1}^{n} X_i = t \right).$$

II.6. Más Ejemplos

Antes de proceder a los cálculos, es conveniente observar que hay casos en los que la muestra observada $\underline{x}_{(n)}$ es incompatible con el valor t de la suma. Como ejemplo, imagine que $n = 5$ y que $t = 3$. Si se considera la muestra observada $\underline{x}_{(5)} = (0,0,0,0,0)$, es evidente que esta muestra es incompatible con la condición de que se hayan registrado tres éxitos. De esta forma,

$$P\left(\underline{X}_{(5)} = (0,0,0,0,0) \,\middle|\, \Sigma_{i=1}^{5} X_i = 3 \right) = 0.$$

En general,

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, T(\underline{X}_{(n)}) = t \right) = 0 \quad \text{si} \quad T\left(\underline{x}_{(n)}\right) \neq t.$$

Por otra parte, si $T\left(\underline{x}_{(n)}\right) = t$, considere los siguientes dos subconjuntos del espacio muestral de dimensión: $A = \left\{ \underline{x}_{(n)} \right\}$ y B, el conjunto de todas la muestras cuya suma es t. Por construcción, $A \subseteq B$ y la probabilidad de interés está dada por

$$P(A \mid B) = \frac{P(A \cap B)}{P(B)}$$

$$= \frac{P(A)}{P(B)}.$$

II.6. Más Ejemplos

Procediendo al cálculo en estas condiciones se tiene

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, T(\underline{X}_{(n)}) = t \right) = \frac{P\left(\underline{X}_{(n)} = \underline{x}_{(n)},\ \Sigma_{i=1}^{n} X_i = t \right)}{P(\Sigma_{i=1}^{n} X_i = t)}$$

$$= \frac{P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \right)}{P\left(\Sigma_{i=1}^{n} X_i = t \right)}$$

$$= \frac{\theta^{\Sigma x_i} (1-\theta)^{n-\Sigma x_i}}{\binom{n}{t} \theta^{t} (1-\theta)^{n-t}}$$

Puesto que $\Sigma_{i=1}^{n} x_i = t$, se tiene que

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, T(\underline{X}_{(n)}) = t \right) = \frac{1}{\binom{n}{t}}.$$

II.6. Más Ejemplos

En resumen, tenemos que

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, T(\underline{X}_{(n)}) = t \right) \quad = \begin{cases} 0 & si \quad T\left(\underline{x}_{(n)}\right) \neq t \\ \dfrac{1}{\binom{n}{t}} & si \quad T\left(\underline{x}_{(n)}\right) = t \end{cases}$$

El resultado final es que la probabilidad condicional

$$P\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, \Sigma_{i=1}^{n} X_i = t \right)$$

es constante; no depende de θ, por lo que podemos afirmar que $\Sigma_{i=1}^{n} X_i$ es una estadística suficiente para el parámetro θ y, en virtud de la relación entre la suma y la media de las variables aleatorias, podemos, también, concluir que $T = \overline{X}$ es una estadística suficiente para θ. Esto es, *el estimador $\hat{\theta} = \overline{X}$ captura **toda** la información contenida en la muestra $\underline{X}_{(n)}$ sobre el parámetro θ*.

II.6. Más Ejemplos

De hecho, en el caso del modelo $Bernoulli(\theta)$, podemos decir que $\hat{\theta} = \overline{X}$ es un estimador del parámetro θ con las siguientes propiedades:

1. *Es insesgado*
2. *Tiene varianza* $\theta(1-\theta)/n$
3. *Su ECM también es* $\theta(1-\theta)/n$
4. *Es consistente en* ECM
5. ***Es suficiente** para* θ

Veamos lo que ocurre con los estimadores de μ y σ^2 en el modelo $Normal$. Consideremos primero el caso en que se estima a la esperanza μ cuando la varianza es conocida.

II.6. Más Ejemplos

***Ejemplo 5**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ con $\sigma^2 > 0$, varianza conocida. Verifique si el estimador $\hat{\mu} = \overline{X}$ es una estadística suficiente para μ.*

En el caso de variables aleatorias continuas, como en este ejemplo, el objeto de análisis es la función de distribución o función de densidad condicionales. Así, es necesario calcular la densidad

$$f_{\underline{X}_{(n)} \mid \overline{X}=t}\left(\underline{x}_{(n)} \right) = f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \mid \overline{X} = t \right)$$

$$= \frac{f_{\underline{X}_{(n)}, \overline{X}}\left(\underline{x}_{(n)}, t \right)}{f_{\overline{X}}(t)}.$$

Sobre la conjunta $f_{\underline{X}_{(n)}, \overline{X}}\left(x_{(n)}, t\right)$, como en el ejemplo previo, dado que $\overline{X}$ es una función de la muestra $\underline{X}_{(n)}$, puede ocurrir que los valores de $\underline{x}_{(n)}$ y t sean incompatibles (cuando $\overline{x} \neq t$), en cuyo caso la densidad toma el valor cero. Si, por el contrario, se tiene que $\overline{x} = t$, entonces siendo $\underline{x}_{(n)}$ una sola de las muestras cuya media muestral es igual a t, el numerador se reduce a $f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \right)$.

II.6. Más Ejemplos

De esta manera, tenemos

$$f\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, \overline{X} = t \right) \quad = \begin{cases} 0 & si \quad \overline{x} \neq t \\ \dfrac{f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \right)}{f_{\overline{X}}(t)} & si \quad \overline{x} = t \end{cases}$$

Evidentemente, si $\overline{x} \neq t$, la condicional no depende de μ. Basta con analizar el caso $\overline{x} = t$. Recordemos que $\underline{X}_{(n)}$ es una colección de variables aleatorias independientes e idénticamente distribuidas de acuerdo con un modelo $Normal(\,\mu, \sigma^2\,)$. Es decir, son una muestra aleatoria de un modelo con función de densidad

$$f(x;\mu) = (2\pi\sigma^2)^{-1/2}\, exp\left\{ -\frac{1}{2\sigma^2}\ (x-\mu)^2 \right\}.$$

II.6. Más Ejemplos

En consecuencia, se tiene

$$f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}\right) = \Pi_{i=1}^{n} f(x_i;\mu)$$

$$= (2\pi\sigma^2)^{-n/2}\, exp\left\{-\frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\,(x_i-\mu)^2\right\}.$$

Por lo que respecta a $\overline{X}$, sabemos que $\overline{X} \sim Normal(\,\mu, \sigma^2/n)$. Así que,

$$f_{\overline{X}}(t) = (2\pi\sigma^2/n\,)^{-1/2}\, exp\left\{-\frac{n}{2\sigma^2}\,(t-\mu)^2\right\}.$$

Por tanto,

$$\frac{f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}\right)}{f_{\overline{X}}(t)} = \frac{(2\pi\sigma^2)^{-n/2}\, exp\left\{-\frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\,(x_i-\mu)^2\right\}}{(2\pi\sigma^2/n\,)^{-1/2}\, exp\left\{-\frac{n}{2\sigma^2}\,(t-\mu)^2\right\}}.$$

II.6. Más Ejemplos

Así, μ aparece en el cociente y, a primera vista, no es evidente que se pueda *eliminar*. Sin embargo, aquí es relevante una igualdad que probamos cuando analizábamos los estimadores de la varianza:

$$\Sigma_{i=1}^{n}\,(x_i-\mu)^2=\Sigma_{i=1}^{n}\,(x_i-\overline{x})^2+n(\overline{x}-\mu)^2.$$

En efecto, sustituyendo en el cociente, se obtiene

$$\frac{f_{\underline{X}_{(n)}}\left(\,\underline{x}_{(n)}\,\right)}{f_{\overline{X}}(t)}=\frac{(2\pi\sigma^2)^{-n/2}\,exp\left\{-\,\frac{1}{2\sigma^2}\;\Sigma_{i=1}^{n}\,(x_i-\overline{x})^2\right\}\,exp\left\{-\,\frac{n}{2\sigma^2}\,(\overline{x}-\mu)^2\right\}}{(2\pi\sigma^2/n\,)^{-1/2}\,exp\left\{-\,\frac{n}{2\sigma^2}\,(t-\mu)^2\right\}}.$$

Si se recuerda que estamos analizando el cociente bajo la condición $\overline{x}=t$, se sigue que

$$\frac{f_{\underline{X}_{(n)}}\left(\,\underline{x}_{(n)}\,\right)}{f_{\overline{X}}(t)}=(2\pi\sigma^2)^{-(n-1)/2}\,n^{-1/2}\,exp\left\{-\,\frac{1}{2\sigma^2}\;\Sigma_{i=1}^{n}\,(x_i-\overline{x})^2\right\}.$$

II.6. Más Ejemplos

que no depende de μ a pesar de que no es constante. En conclusión,

$$f\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, \overline{X} = t \right) = \begin{cases} 0 & si \quad \overline{x} \neq t \\ (2\pi\sigma^2)^{-(n-1)/2}\, n^{-1/2}\, exp\left\{ -\dfrac{1}{2\sigma^2} \Sigma_{i=1}^{n} (x_i - \overline{x})^2 \right\} & si \quad \overline{x} = t \end{cases}$$

y, por tanto, se tiene que la estadística $\overline{X}$ es suficiente para el parámetro μ en este caso. En términos de estimación puntual, $\hat{\mu} = \overline{X}$ como estimador de μ es

1. *Insesgado.*
2. *Tiene varianza (y ECM) igual a σ^2/n.*
3. *Es consistente en ECM.*
4. *Es suficiente para μ.*

II.6. Más Ejemplos

***Ejemplo 6**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ con $\mu \in \mathbb{R}$, conocida. Verifique si el estimador $\hat{\sigma}^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2$ es una estadística suficiente para σ^2.*

De nuevo, es necesario calcular la densidad

$$f_{\underline{X}_{(n)}\,|\hat{\sigma}^2=t}\left(\underline{x}_{(n)}\right) = f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \mid \hat{\sigma}^2 = t\right)$$

$$= \frac{f_{\underline{X}_{(n)},\hat{\sigma}^2}\left(\underline{x}_{(n)}, t\right)}{f_{\hat{\sigma}^2}(t)}.$$

Una vez mas, dado que $\hat{\sigma}^2$ es una función de la muestra $\underline{X}_{(n)}$, puede ocurrir que los valores de $\underline{x}_{(n)}$ y t sean incompatibles (cuando $\frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2$ no coincida con el valor t), en cuyo caso la densidad conjunta toma el valor cero. Si, por el contrario, los valores coinciden, entonces siendo $\underline{x}_{(n)}$ una sola de las muestras cuya varianza muestral es igual a t, el numerador se reduce a $f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}\right)$.

II.6. Más Ejemplos

Así, tenemos

$$f\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, \hat{\sigma}^2 = t \right) \quad = \begin{cases} 0 & si \quad \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2 \neq t \\ \dfrac{f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \right)}{f_{\hat{\sigma}^2}(t)} & si \quad \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2 = t \end{cases}$$

Si ocurre que $\frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2 \neq t$, la condicional no depende de σ^2. Basta con analizar el oro caso. Al igual que en el ejemplo previo, $\underline{X}_{(n)}$ es una colección de variables aleatorias independientes e idénticamente distribuidas de acuerdo con un modelo $Normal(\,\mu, \sigma^2\,)$. Es decir, son una muestra aleatoria de un modelo con función de densidad

$$f(x; \sigma^2) = (2\pi\sigma^2)^{-1/2}\, exp\left\{ - \frac{1}{2\sigma^2} \;\; (x - \mu)^2 \right\}.$$

II.6. Más Ejemplos

En consecuencia, se tiene

$$f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}\right) = \Pi_{i=1}^{n} f(x_i;\mu)$$

$$= (2\pi\sigma^2)^{-n/2}\, exp\left\{-\frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\,(x_i-\mu)^2\right\}.$$

Por lo que respecta a $\hat{\sigma}^2$, sabemos que $\frac{n}{\sigma^2}\hat{\sigma}^2 \sim \mathcal{X}^2_{(n)}$. De esta forma,

$$f_{\hat{\sigma}^2}(t) = \frac{(1/2)^{n/2}}{\Gamma(n/2)}\ (t\,)^{\,n/2\,-\,1}\,(\sigma^2/n\,)^{\,-n/2}\ exp\left\{-\frac{n}{2\sigma^2}\ t\right\}.$$

Por tanto,

$$\frac{f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)}\right)}{f_{\hat{\sigma}^2}(t)} = \frac{(2\pi\sigma^2)^{-n/2}\, exp\left\{-\frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\,(x_i-\mu)^2\right\}}{\frac{(1/2)^{n/2}}{\Gamma(n/2)}\ (t\,)^{\,n/2\,-\,1}\,(\sigma^2/n\,)^{\,-n/2}\ exp\left\{-\frac{n}{2\sigma^2}\ t\right\}}.$$

II.6. Más Ejemplos

Observando que $\Sigma_{i=1}^{n}\,(x_i-\mu)^2 = nt$, se sigue que

$$\frac{f_{\underline{X}_{(n)}}\left(\,\underline{x}_{(n)}\,\right)}{f_{\widehat{\sigma}^2}(t)} = \frac{\Gamma(n/2)(\pi n)^{-n/2}}{(t)^{\,n/2\,-\,1}}.$$

que no depende de σ^2. En resumen, tenemos que

$$f\left(\,\underline{X}_{(n)} = \underline{x}_{(n)}\,\middle|\,\hat{\sigma}^2 = t\,\right) \quad = \begin{cases} 0 & si \quad \Sigma_{i=1}^{n}\,(x_i-\mu)^2 \neq nt \\ \dfrac{\Gamma(n/2)(\pi n)^{-n/2}}{(t)^{\,n/2\,-\,1}} & si \quad \Sigma_{i=1}^{n}\,(x_i-\mu)^2 = nt \end{cases}$$

En conclusión, $\hat{\sigma}^2$ es suficiente para σ^2.

II.6. Más Ejemplos

Finalmente, se tiene que el estimador $\hat{\sigma}^2$ tiene las siguientes propiedades:

1. *Es insesgado.*
2. *Tiene varianza (y ECM) igual a $2\sigma^4/n$.*
3. *Es consistente en ECM.*
4. *Es suficiente para σ^2.*

Tarea. *Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\mu \in \mathbb{R}$, es conocida. Verifique si el estimador $\hat{\sigma}_1^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \overline{x})^2$ es una estadística suficiente para σ^2.*

II.6. Más Ejemplos

Volvamos al modelo $Uniforme$ continua, donde tenemos dos estimadores del parámetro θ.

***Ejemplo 7**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Uniforme(0,\theta)$ con $\theta > 0$. Verifique si los estimadores $\hat{\theta}_1 = 2\overline{X}$ y $\hat{\theta}_2 = X_{(n)}$ son suficientes para θ.*

Iniciemos el análisis con el caso de $\hat{\theta}_2 = X_{(n)}$. De los ejemplos previos sabemos que

$$f\left(\underline{X}_{(n)} = \underline{x}_{(n)} \mid \hat{\theta}_2 = t \right) = \begin{cases} 0 & si \quad x_{(n)} \neq t \\ \dfrac{f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \right)}{f_{\hat{\theta}_2}(t)} & si \quad x_{(n)} = t \end{cases}$$

II.6. Más Ejemplos

La función de densidad del modelo $Uniforme(0, \theta)$ está dada por:

$$f(x;\theta) = \begin{cases} 0 & x \leq 0 \\ 1/\theta & 0 < x < \theta \\ 0 & x \geq \theta \end{cases}$$

que se puede representar como

$$f(x;\theta) = \frac{1}{\theta}\, \mathbf{1}_{(0,\theta)}(x)$$

con

$$\mathbf{1}_A(x) = \begin{cases} 1 & si \quad x \in A \\ 0 & si \quad x \notin A \end{cases}$$

II.6. Más Ejemplos

Por tanto la función de densidad conjunta de la muestra resulta:

$$
\begin{aligned}
f_{\underline{X}_{(n)}}\left(\underline{x}_{(n)} \; ; \; \theta \right) &= \Pi_{i=1}^{n} f(x_i; \theta) \\
&= \Pi_{i=1}^{n} \left\{ \frac{1}{\theta} \; \mathbf{1}_{(0,\theta)}(x_i) \right\} \\
&= \frac{1}{\theta^n} \Pi_{i=1}^{n} \mathbf{1}_{(0,\theta)}(x_i) \\
&= \frac{1}{\theta^n} \; \mathbf{1}_{(0,\theta)}\left(x_{(n)}\right)
\end{aligned}
$$

II.6. Más Ejemplos

Por otra parte, sabemos que la función de densidad de probabilidad del máximo X está dada por:

$$f_{X_{(n)}}(t) = \begin{cases} 0 & t \leq 0 \\ n\,[t/\theta]^{n-1}(1/\theta) & 0 < t < \theta \\ 0 & t \geq \theta \end{cases}$$

que se puede escribir como

$$f_{X_{(n)}}(t) = \frac{1}{\theta^n}\, nt^{n-1}\, \mathbf{1}_{(0,\theta)}(t)$$

Así que

$$\frac{f_{\underline{X}_{(n)}}\left(\,\underline{x}_{(n)}\,\right)}{f_{\widehat{\theta}_2}(t)} = \frac{\frac{1}{\theta^n}\, \mathbf{1}_{(0,\theta)}\left(x_{(n)}\right)}{\frac{1}{\theta^n}\, nt^{n-1}\, \mathbf{1}_{(0,\theta)}(t)}$$

$$= \frac{\mathbf{1}_{(0,\theta)}\left(x_{(n)}\right)}{nt^{n-1}\, \mathbf{1}_{(0,\theta)}(t)}$$

II.6. Más Ejemplos

De forma que

$$f\left(\underline{X}_{(n)} = \underline{x}_{(n)} \,\middle|\, X_{(n)} = t \right) = \begin{cases} 0 & si \quad x_{(n)} \neq t \\ \dfrac{\mathbf{1}_{(0,\theta)}\left(x_{(n)}\right)}{nt^{n-1}\,\mathbf{1}_{(0,\theta)}(t)} & si \quad x_{(n)} = t \end{cases}$$

$$= \begin{cases} 0 & si \quad x_{(n)} \neq t \\ \dfrac{1}{nt^{n-1}} & si \quad x_{(n)} = t \end{cases}$$

de donde se concluye que $X_{(n)}$ es suficiente para θ.

II.6. Más Ejemplos

Tarea. *Aplicando el mismo procedimiento, verifique si $\hat{\theta}_1 = 2\overline{X}$ es suficiente para θ.*

Sobre esta tarea vale la pena comentar que para determinar si $2\overline{X}$ es suficiente para θ, basta con verificar que $Y = \Sigma_{i=1}^{n} X_i$ es suficiente para este parámetro. Sin embargo, para calcular la densidad conjunta condicional de la muestra, dado un valor fijo de Y, se requiere el cálculo de la función de densidad de Y.

En una tarea previa se identificó que la distribución de Y está directamente relacionada con la de la suma de n variables aleatorias con distribución $Uniforme(0,1)$, que se conoce como el modelo de Irwin-Hall.

Esta distribución, tiene una función de densidad continua que se define por pedazos con un polinomio de orden $n-1$ para cada intervalo de la forma $I_j = (j-1,\ j); j = 1, 2, \dots, n$. Se conoce la representación explícita de esta densidad y ya reportarán en la tarea si este modelo presenta complicaciones que dificulten la verificación de suficiencia del estimador.