II.10. La Cota Inferior de Cramér y Rao

Existen más criterios para la evaluación de estimadores que podríamos examinar. Sin embargo, vamos a detenernos aquí. *Insesgamiento*, *Varianza mínima (ECM mínimo)*, *Consistencia (en ECM)* y *Suficiencia* constituyen una catálogo bastante completo.

Ahora bien, sobre estos criterios es interesante observar que algunos criterios son absolutos. Así, un estimador puede ser insesgado o no; es una condición cualitativa que sólo es atribuible al propio estimador. Lo mismo ocurre con la consistencia; un estimador es consistente o no lo es.

En tercer lugar tenemos la suficiencia; de nuevo, un estimador es suficiente o no lo es, en términos absolutos. En contraste, el criterio de varianza mínima, es relativo. Un estimador es de varianza mínima (ECM mínimo) sólo en comparación con un conjunto de otros estimadores.

Esta relatividad fue identificada por distintos autores y, en consecuencia, se plantearon la correspondiente pregunta en términos absolutos: ¿existe el estimador (insesgado) de varianza mínima ***absoluta***, es decir, con varianza menor que la cualquier otro estimador insesgado? Por supuesto, también se preguntaron ¿Cuál es esa varianza mínima?

II.10. La Cota Inferior de Cramér y Rao

Considerando que el espacio de todos los estimadores es, en general, de dimensión infinita, el problema de determinar el que, de entre todos ellos, sea el insesgado de menor varianza es una tarea cuya meta parece inalcanzable.

Fue necesario que aparecieran en escena dos gigantes de la Estadística para que este problema tuviera una solución que además es impresionantemente simple cuando se examina en retrospectiva. Estos dos protagonistas fueron *Harald Cramér* y *Calyampudi Radhakrishna Rao*, mejor conocido como C.R. Rao. Extraordinarios científicos los dos, Cramer falleció en 1985 a la edad de 92 años, mientras que Rao está celebrando su cumpleaños 100 en septiembre de 2020.

Tarea. *Prepare una nota biográfica de cada uno de estos destacados estadísticos, Cramér y Rao.*

Volviendo al discurso original, estos dos científicos, entre otros muchos logros, probaron dos teoremas que ahora se consideran centrales en la Estadística Matemática y cuyo propósito es determinar *¿Cuál es la varianza mas pequeña que un estimador insesgado puede alcanzar?* y *¿Existe un estimador insesgado cuya varianza alcance esa cota?*

II.10. La Cota Inferior de Cramér y Rao

La idea es que si $\hat{\theta}$ es un estimador insesgado cualquiera del parámetro θ que identifica al modelo $f(x\,;\,\theta)$, entonces se identifique una constante c que sirva como cota inferior para la varianza de $\hat{\theta}$. Como hemos comprobado, la varianza de estimador en general depende del parámetro que se estima, del modelo al que corresponde y del tamaño que tenga la muestra. En consecuencia, la constante debe depender de estos elementos. Es decir, debe ocurrir que la cota sea de la forma

$$c = c(f, \theta, n).$$

Por otra parte, la cota no puede depender del estimador. Debe ser una cota general para la varianza de ***todos*** los estimadores insesgados del parámetro θ, asociado al modelo $f(x\,;\,\theta)$ y que se producen a partir de una muestra aleatoria de tamaño n de ese modelo.

Los dos resultados que vamos a presentar se conocen como los teoremas de Cramér y Rao. El primero establece una cota inferior para la varianza de todo estimador insesgado del parámetro de interés, mientras que el segundo provee un mecanismo para buscar el estimador cuya varianza alcanza la cota si es que este estimador existe. Veamos el primer teorema.

II.10. La Cota Inferior de Cramér y Rao

Teorema (Cramér y Rao, parte I). *Sea $\underline{X}_{(n)}$ una muestra aleatoria de una v. a. X, con f.d.p.g $f(x\,;\,\theta)$ donde $\theta \in \mathbb{R}$. Entonces, si $\hat{\theta}$ es un estimador insesgado de θ, y existe su varianza, se tiene que, bajo condiciones relativamente generales,*

$$Var(\hat{\theta}) \;\geq\; \frac{1}{E\left\{\left(\frac{d}{d\theta}\ln f(\underline{X}_{(n)};\theta)\right)^2\right\}}.$$

La demostración tiene dos partes. La primera que utiliza ideas y conceptos básicos de probabilidad y una segunda, que comprueba el genio de Cramér y Rao.

Demostración. Sean U y V dos variables aleatorias tales que existen $E(U)$, $E(V)$, $Var(U)$, $Var(V)$ y $Cov(U,V)$. Sea además, $W = U + kV$ con k una constante. La existencia de los momentos respectivos de U y V garantiza la existencia de la varianza de W, de manera que

$$Var(W) = Var(U + kV)$$

II.10. La Cota Inferior de Cramér y Rao

Aplicando las propiedades del operador varianza, se tiene que

$$
\begin{aligned}
Var(W) &= Var(U + kV) \\
&= Var(U) + Var(kV) + 2Cov(U, kV) \\
&= Var\ (U) + k^2\ Var(V) + 2k\ Cov(U.V) \\
&= ak^2 + bk + c.
\end{aligned}
$$

Ahora bien, por definición, $Var(W) \geq 0$. Esto significa que para toda $k \in \mathbb{R}$, la parábola definida por $g(k) = ak^2 + bk + c$, toma un valor no negativo. En otras palabras, esta ecuación de segundo grado, o bien no tiene raíces reales o sólo tiene una raíz real. En términos del correspondiente discriminante $\Delta = b^2 - 4ac$, se debe cumplir que $\Delta \leq 0$. En consecuencia, se tiene que

$$4(Cov(U, V))^2 - 4\ Var(U)\ Var(V) \ \leq \ 0.$$

II.10. La Cota Inferior de Cramér y Rao

Equivalentemente,

$$(Cov(U,V))^2 \leq Var(U)\, Var(V)$$

de donde se sigue que

$$Var\,(V) \quad \geq \quad \frac{\left(Cov(U,V)\right)^2}{Var(U)}.$$

Así, si V es un estimador insesgado $\hat{\theta}$ de θ, entonces su varianza queda acotada inferiormente de acuerdo con la desigualdad

$$Var\,\left(\hat{\theta}\right) \quad \geq \quad \frac{\left(Cov\left(U,\hat{\theta}\right)\right)^2}{Var(U)}.$$

El término en el extremo derecho, sin embargo, no sirve como la cota que se busca puesto que cambia para cada estimador debido a la covarianza $Cov\left(U,\hat{\theta}\right)$ y, por otra parte, la variable aleatoria U no ha sido especificada.

II.10. La Cota Inferior de Cramér y Rao

Esta es la que se puede denominar, la primera parte de la demostración. En la segunda parte, los se propone una variable aleatoria U, de manera que la covarianza $Cov\left(U, \hat{\theta}\right)$ es independiente de $\hat{\theta}$, siempre que este sea un estimador insesgado de θ. Entre las ideas que se pueden ocurrir en una primera instancia, está la de una variable U que fuese independiente de cualquier estimador insesgado. Esta opción, sin embargo, no es útil ya que en ese caso $Cov\left(U, \hat{\theta}\right) = 0$ y la cota resultaría también igual a cero y, por tanto irrelevante.

La solución no es evidente y por ello, la contribución de Cramér y Rao es tan valiosa. Su propuesta, que en principio no parece intuitiva, es la siguiente

$$U = \frac{d}{d\theta} \ln f\left(\underline{X}_{(n)};\ \theta\right).$$

Observe que U es función tanto del parámetro θ, como de la muestra $\underline{X}_{(n)}$, a la que debe su aleatoriedad. Analicemos las propiedades de esta variable aleatoria.

II.10. La Cota Inferior de Cramér y Rao

Para empezar, observe que

$$\frac{d}{d\theta}\ln f(\underline{X}_{(n)};\,\theta) \;=\; \left(f(\underline{X}_{(n)};\,\theta)\right)^{-1}\left(\frac{d}{d\theta}f(\underline{X}_{(n)};\,\theta)\right).$$

Calculemos la esperanza de U. Consideraremos el caso continuo; en el caso discreto, las integrales se deben reemplazar por sumas. Procedamos:

$$\begin{aligned} E(U) \;&=\; \int U(\underline{x}_{(n)})\, f\left(\underline{x}_{(n)};\,\theta\right) d\underline{x}_{(n)} \\ &=\; \int \left(f(\underline{x}_{(n)};\,\theta)\right)^{-1}\left(\frac{d}{d\theta}f(\underline{x}_{(n)};\,\theta)\right) f\left(\underline{x}_{(n)};\,\theta\right) d\underline{x}_{(n)} \\ &=\; \int \left(\frac{d}{d\theta}f(\underline{x}_{(n)};\,\theta)\right) d\underline{x}_{(n)} \end{aligned}$$

II.10. La Cota Inferior de Cramér y Rao

Por tanto,

$$E(U) = \int \frac{d}{d\theta} f(\underline{X}_{(n)};\ \theta)\ d\underline{x}_{(n)}\,.$$

Ahora, observe que los operadores de diferenciación e integración no se cancelan porque la integración es respecto a la muestra mientras que la diferenciación es respecto al parámetro. Sin embargo, bajo algunas condiciones relativamente generales, estos dos operadores se pueden permutar. En particular, debe ocurrir que el soporte de la muestra no dependa del valor del parámetro. Estas son las condiciones a las que se refiere el enunciado del teorema. El caso es que si esta permutación es válida, se tiene que

$$\begin{aligned} E(U) &= \frac{d}{d\theta}\left(\int f(\underline{X}_{(n)};\ \theta)\ d\underline{x}_{(n)}\right) \\ &= 0. \end{aligned}$$

II.10. La Cota Inferior de Cramér y Rao

Como consecuencia,

$$\begin{aligned} Var(U) &= E(U^2) - (E(U))^2 \\ &= E(U^2). \end{aligned}$$

Por otra parte, en cuanto a la covarianza se observa que

$$\begin{aligned} Cov\left(U, \hat{\theta}\right) &= E\left(U\,\hat{\theta}\right) - E(U)E(\hat{\theta}) \\ &= E\left(U\,\hat{\theta}\right) \\ &= \int U\left(\underline{x}_{(n)}\right)\hat{\theta}\, f\left(\underline{x}_{(n)};\ \theta\right) d\underline{x}_{(n)} \end{aligned}$$

II.10. La Cota Inferior de Cramér y Rao

Así que,

$$
\begin{aligned}
Cov\left(U, \hat{\theta}\right) &= \int U\left(\underline{x}_{(n)}\right) \hat{\theta}\, f\left(\underline{x}_{(n)};\, \theta\right) d\underline{x}_{(n)} \\
&= \int \hat{\theta}\, \left(f\left(\underline{x}_{(n)};\, \theta\right)\right)^{-1} \left(\frac{d}{d\theta} f\left(\underline{x}_{(n)};\, \theta\right)\right) f\left(\underline{x}_{(n)};\, \theta\right) d\underline{x}_{(n)} \\
&= \int \hat{\theta} \left(\frac{d}{d\theta} f\left(x_{(n)};\, \theta\right)\right) d\underline{x}_{(n)}\,. \\
&= \int \frac{d}{d\theta} \left\{ \hat{\theta}\, f\left(\underline{x}_{(n)}; \theta\right) \right\} d\underline{x}_{(n)}
\end{aligned}
$$

II.10. La Cota Inferior de Cramér y Rao

Entonces,

$$Cov(U,\hat{\theta}) \;=\; \int \frac{d}{d\theta}\;\left\{\,\hat{\theta}\;f\left(\underline{x}_{(n)};\theta\right)\right\}\,d\underline{x}_{(n)}\,.$$

Si de nuevo se intercambian diferenciación e integral,

$$Cov(U,\hat{\theta}) \;=\; \frac{d}{d\theta}\;\left\{\int \hat{\theta}\;f(\underline{x}_{(n)};\;\theta)\;d\underline{x}_{(n)}\right\}$$

$$= \;\frac{d}{d\theta}\;\left\{E(\hat{\theta})\right\}$$

$$= \;1.$$

II.10. La Cota Inferior de Cramér y Rao

Finalmente,

$$Var(\hat{\theta}) \ \geq \ \frac{1}{E(U^2)},$$

es decir,

$$Var(\hat{\theta}) \ \geq \ \frac{1}{E\left(\left(\frac{d}{d\theta}\ln f\left(\underline{X}_{(n)};\ \theta\right)\right)^2\right)}.$$

lo que finaliza la demostración. A la cantidad

$$CICR(\theta) \ = \ \frac{1}{E\left(\left(\frac{d}{d\theta}\ln f\left(\underline{X}_{(n)};\ \theta\right)\right)^2\right)}$$

se le conoce como la *Cota Inferior de Cramér y Rao* y ahora ilustraremos su cálculo en algunos ejemplos.

II.11. Ejemplos

Antes de los ejemplos, una ***Tarea.*** *Investigue y escriba un reporte de las condiciones suficientes para que el intercambio de los operadores de integración y diferenciación sea válido.*

Ejemplo 9*. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Bernoulli(\theta)$ donde $\theta \in (0,1)$. Determine la $CICR(\theta)$ para la varianza de* ***todo*** *estimador insesgado de θ.*

Para calcular la $CICR(\theta)$ es necesario calcular la variable aleatoria U y su esperanza $E(U^2)$. En este caso,

$$P\left(\underline{X}_{(n)};\ \theta\right) \ = \ \theta^{\Sigma X_i}\,(1-\theta)^{n-\Sigma X_i}$$

de manera que

$$\ln P\left(\underline{X}_{(n)}\ ;\ \theta\right) \ = \ (\Sigma X_i)\ln\theta + \ (n-\Sigma X_i)\ln(1-\theta)$$

y entonces,

$$\frac{d}{d\theta}\ln P\left(\underline{X}_{(n)}\ ;\ \theta\right) \ = \ \frac{\Sigma X_i}{\theta} - \frac{n-\Sigma X_i}{1-\theta}.$$

II.11. Ejemplos

Así, operando con las fracciones se obtiene

$$U = \frac{\Sigma X_i - n\theta}{\theta(1-\theta)}.$$

En consecuencia,

$$E(U^2) = \frac{E\{\,(\Sigma X_i - n\theta)^2\}}{\{\theta(1-\theta)\}^2}$$

y, como sabemos que

$$Y = \Sigma_{i=1}^{n} X_i \sim Bin(n, \theta),$$

entonces

$$E\{\,(\Sigma X_i - n\theta)^2\} = Var(Y)$$

$$= n\theta(1-\theta).$$

II.11. Ejemplos

Por último, resulta que

$$E(U^2) = \frac{n\,\theta(1-\theta)}{\{\theta(1-\theta)\}^2}$$

$$= \frac{n}{\theta(1-\theta)}\,.$$

Finalmente, tenemos que

$$CICR(\theta) = \frac{\theta(1-\theta)}{n}.$$

De esta forma, la cota inferior para la varianza de cualquier estimador insesgado de θ, en el modelo $Bernoulli(\theta)$, está dada por $\theta(1-\theta)/n$. Ahora si retrocedemos un poco, habremos de recordar que $\hat{\theta} = \overline{X}$ es un estimador insesgado de θ, cuya varianza es precisamente $\theta(1-\theta)/n$. Es decir, resulta que *$\hat{\theta} = \overline{X}$, no solo es suficiente para θ y consistente, sino que, además, es el estimador insesgado de varianza mínima (en absoluto). En inglés, el **MVUE** (Minimum Variance Unbiased Estimator).*

II.11. Ejemplos

***Ejemplo 10**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\mu \in \mathbb{R}$. Determine la $CICR(\mu)$ para la varianza de **todo** estimador insesgado de μ.*

Calculemos la variable aleatoria U

$$f\left(\underline{X}_{(n)};\ \mu\right) \ = \ (2\pi\sigma^2)^{-n/2}\ exp\left\{-\ \frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\ (x_i - \mu)^2\right\}$$

aplicando logaritmo,

$$\ln f\left(\underline{X}_{(n)}\ ;\ \mu\right) \ = \ -\frac{n}{2} ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\ (x_i - \mu)^2$$

y derivando,

$$\frac{d}{d\mu} \ln f\left(\underline{X}_{(n)}\ ;\ \mu\right) \ = -\ \frac{1}{2\sigma^2}\ \Sigma_{i=1}^{n}\ 2\ (x_i - \mu)(-1)$$

II.11. Ejemplos

De esta forma

$$\frac{d}{d\mu}\ln f\left(\underline{X}_{(n)}\,;\,\mu\right) = \frac{1}{\sigma^2}\left(\Sigma_{i=1}^{n}x_i - n\mu\right)$$

Así que

$$U = \frac{n}{\sigma^2}\left(\overline{X} - \mu\right).$$

Entonces,

$$E(U^2) = \frac{n^2}{\sigma^4}\,E\left\{\left(\overline{X} - \mu\right)^2\right\}$$

$$= \frac{n^2}{\sigma^4}\,Var\left(\overline{X}\right)$$

$$= \frac{n^2}{\sigma^4}\,\frac{\sigma^2}{n}.$$

II.11. Ejemplos

Por tanto, $E(U^2) = n/\sigma^2$. En consecuencia, en este caso tenemos que

$$CICR(\mu) = \frac{\sigma^2}{n}.$$

Observe que para este cálculo no fue necesario suponer que la varianza σ^2 fuese conocida. El valor de la cota no cambia excepto que, a su vez, puede ser conocida o desconocida. El análisis que se produce es el mismo en cualquiera de los dos casos. Como primera conclusión, se tiene que la varianza de todo estimador insesgado de μ debe ser mayor o igual a σ^2/n. Previamente, sabíamos que $\overline{X}$ es un estimador insesgado, consistente y suficiente de μ, cuya varianza es precisamente σ^2/n. Entonces, como segunda conclusión tenemos que *$\hat{\mu} = \overline{X}$ es el estimador insesgado de varianza mínima entre **todos** los estimadores insesgados de μ. Es el **MVUE.*** Ahora, consideremos otro ejemplo.

***Ejemplo 11**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\sigma^2 > 0$. Determine la $CICR(\sigma^2)$ para la varianza de **todo** estimador insesgado de σ^2.*

II.11. Ejemplos

Procedamos con la variable aleatoria U

$$f\left(\underline{X}_{(n)};\sigma^2\right) \;=\; (2\pi\sigma^2)^{-n/2}\, exp\left\{-\frac{1}{2\sigma^2}\;\Sigma_{i=1}^{n}\,(x_i-\mu)^2\right\}$$

aplicando logaritmo,

$$ln\, f\left(\underline{X}_{(n)}\,;\sigma^2\right) \;=\; -\frac{n}{2}ln(2\pi\sigma^2) - \frac{1}{2\sigma^2}\;\Sigma_{i=1}^{n}\,(x_i-\mu)^2$$

y derivando,

$$\frac{d}{d\sigma^2}\;ln\, f\left(\underline{X}_{(n)}\,;\sigma^2\right) \;=\; -\frac{n}{2}\,\frac{2\pi}{2\pi\sigma^2} + \frac{1}{2\sigma^4}\Sigma_{i=1}^{n}\,(x_i-\mu)^2$$

$$= -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^2}\left[\frac{n}{\sigma^2}\;\hat{\sigma}^2\right]$$

con $\hat{\sigma}^2 = \Sigma_{i=1}^{n}\,(x_i-\mu)^2/n$, que es un estimador de σ^2 únicamente si μ es conocido.

II.11. Ejemplos

De manera que

$$U = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^2}\left[\frac{n}{\sigma^2}\,\hat{\sigma}^2\right].$$

Recordando que $E(U) = 0$, tenemos que $E(U^2) = Var(U)$ y entonces,

$$E(U^2) = Var\left(-\frac{n}{2\sigma^2} + \frac{1}{2\sigma^2}\left[\frac{n}{\sigma^2}\,\hat{\sigma}^2\right]\right)$$

$$= Var\left(\frac{1}{2\sigma^2}\left[\frac{n}{\sigma^2}\,\hat{\sigma}^2\right]\right)$$

$$= \frac{1}{4\sigma^4}\,Var\left(\frac{n}{\sigma^2}\,\hat{\sigma}^2\right)$$

$$= \frac{n}{2\sigma^4}.$$

II.11. Ejemplos

Como resultado se tiene que

$$CICR(\sigma^2) = \frac{2\sigma^4}{n}.$$

Se concluye que todo estimador insesgado de σ^2 tiene una varianza mayor o igual a $2\sigma^4/n$. Ahora, retomando los resultados que ya utilizamos de ejemplos previos, sabemos que, *si μ es conocida*, la variable aleatoria

$$\hat{\sigma}^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \mu)^2$$

es un estimador insesgado de σ^2, cuya varianza alcanza la cota. Por lo tanto, *$\hat{\sigma}^2$ es el **MVUE** en el caso en que μ es conocida*. Es interesante observar que, de nuevo, el cálculo de la cota no depende de que μ sea conocida y que cuando esta esperanza no es conocida, $\hat{\sigma}^2$ ya no es una estadística y por lo mismo, no es un estimador. En esa situación, hemos propuesto el estimador alternativo

$$\hat{\sigma}_1^2 = \frac{1}{n}\Sigma_{i=1}^{n}(x_i - \overline{x})^2.$$

II.11. Ejemplos

Ahora bien, $\hat{\sigma}_1^2$ no es insesgado. Por tanto, no tiene sentido comparar su varianza con la cota. Sin embargo, a partir de $\hat{\sigma}_1^2$ se puede definir

$$\tilde{\sigma}^2 = \frac{n}{n-1}\,\hat{\sigma}_1^2$$

que resulta insesgado.

Tarea. *Determine si, cuando μ es desconocida, $\hat{\sigma}_1^2$ es el **MVUE** de σ^2.*

En el repaso de los ejemplos que hemos abordado previamente, es importante observar que el cálculo de la $CICR$ no procede en el caso de la distribución $Uniforme$ debido a que en ese modelo el soporte de la variable aleatoria depende del parámetro de interés y, entonces, el intercambio de integral por derivada ya no es posible. En sustitución, considere el siguiente otro ejemplo.

***Ejemplo 12**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con función de densidad $f(x;\lambda) = \lambda\, exp(-\lambda\, x)$ con $\lambda > 0$ y $x > 0$. Determine la $CICR(\lambda)$ para la varianza de **todo** estimador insesgado deλ.*

II.11. Ejemplos

La función de densidad conjunta de la muestra resulta

$$f\left(\underline{X}_{(n)};\lambda\right) \;=\; \Pi_{i=1}^{n}\,\{\lambda\, exp(-\lambda\, x_i)\}$$

$$=\; \lambda^n\;\; exp(-\,\lambda\,\Sigma_{i=1}^{n}\, x_i)$$

Así que, tomando el logaritmo

$$\ln f\left(\underline{X}_{(n)};\lambda\right) \;\; = n\ln\lambda - \lambda\,\Sigma_{i=1}^{n}\, x_i.$$

Entonces U resulta

$$U \;=\; \frac{d}{d\lambda}\ln f\left(\underline{X}_{(n)};\lambda\right)$$

$$=\;\; \frac{n}{\lambda} \;-\; \Sigma_{i=1}^{n}\, x_i.$$

II.11. Ejemplos

Nuevamente, utilizando $E(U) = 0$, tenemos que $E(U^2) = Var(U)$ y entonces,

$$
\begin{aligned}
E(U^2) &= Var\left(\frac{n}{\lambda} - \Sigma_{i=1}^{n} x_i \right) \\
&= Var(\Sigma_{i=1}^{n} x_i) \\
&= \Sigma_{i=1}^{n} Var(x_i) \\
&= \Sigma_{i=1}^{n} Var(x_i) \\
&= \frac{n}{\lambda^2}
\end{aligned}
$$

Así que, *la $CICR$ para la varianza de todos los estimadores insesgados del parámetro λ en este modelo $Exponencial$ resulta λ^2/n.* Ahora bien, para el parámetro de este modelo no hemos propuesto estimador alguno de manera que aquí, a diferencia de los ejemplos previos, no tenemos candidato al ***MVUE***.

II.11. Ejemplos

Esta ausencia de estimadores la podemos subsanar procediendo, como antes, con la idea de *analogía*.

***Ejemplo 13**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con función de densidad $f(x;\lambda) = \lambda\, exp(-\lambda\, x)$ con $\lambda > 0$ y $x > 0$. Proponga un estimador del parámetro λ.*

En este modelo se puede comprobar fácilmente que $E(X) = 1/\lambda$. Entonces, ya que de acuerdo a la idea de analogía, la media poblacional $E(X)$ se aproxima o estima con la media muestral $\overline{x}$, el argumento se puede extender -como en el caso de la distribución $Uniforme$- para, a partir de la relación

$$\lambda \;=\; 1/E(X)$$

proponer el estimador $\hat{\lambda} = 1\,/\,\overline{x}$. La pregunta es si este estimador es insesgado. Veamos

$$E\left(\hat{\lambda}\right) \;=\; E\left(1\,/\,\overline{X}\right)$$

$$= \; n\, E(1\,/\,\Sigma_{i=1}^{n} X_i\,).$$

II.11. Ejemplos

Con las propiedades (lineales) del operador Esperanza no podemos llegar más lejos en este cálculo. Sin embargo, si se define $Y = \Sigma_{i=1}^{n} X_i$, sabemos que la suma de variables aleatorias i.i.d. $Exponencial(\lambda)$ se distribuye como una $Gamma(n, \lambda)$ y más aún, $V = Y^{-1}$ se distribuye como una $Gamma - inversa(n, \lambda)$. ***Tarea.*** *Demuestre que $E(V) = \lambda \,/\, (n-1)$.*

En consecuencia, se tiene que

$$\begin{aligned} E(\hat{\lambda}) &= n\, E(V) \\ &= \left(\frac{n}{n-1}\right) \lambda \end{aligned}$$

y, por lo tanto, no es insesgado, así que no le aplica la $CICR$. Ahora bien, es evidente que si se define $\hat{\lambda}_1 = [(n-1) \,/\, n]\, \hat{\lambda}$, se tiene un estimador de λ que sí es insesgado.

Tarea. *Verifique si el estimador $\hat{\lambda}_1$ es MVUE para λ.*

II.12. Expresiones alternativas de la Cota

Los cálculos necesarios para determinar la cota $CICR(\theta)$ en los ejemplos que hemos presentado no presenta mayores dificultades. Si bien, es necesario calcular la esperanza de una forma cuadrática, al identificar esa esperanza con la correspondiente varianza los operaciones se han facilitado.

En cualquier caso, pueden existir casos en que esta estructura complique la determinación de la cota. En ese sentido, resulta útil contar con una expresión alternativa que no depende de esa forma cuadrática. Por otra parte, ocurre que la versión alternativa de la cota permite, como veremos, una interpretación muy interesante, en términos del concepto de información.

Preposición. *Sea $\underline{X}_{(n)}$ una muestra aleatoria de una v. a. X, con f.d.p.g $f(x\,;\,\theta)$ donde $\theta \in \mathbb{R}$. Entonces, bajo las condiciones generales que requiere el Teorema de Cramer y Rao, se tiene que*

$$E\left\{\left(\frac{d}{d\theta} ln\, f(\underline{X}_{(n)};\theta)\right)^2\right\} = -E\left\{\frac{d^2}{d\theta^2} ln\, f\left(\underline{X}_{(n)};\theta\right)\right\}.$$

II.12. Expresiones alternativas de la Cota

Demostración. Empecemos por detallar el cálculo de la segunda derivada

$$\begin{aligned}\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta) &= \frac{d}{d\theta}\left(\frac{d}{d\theta}\ln f(\underline{X}_{(n)};\ \theta)\right)\\ &= \frac{d}{d\theta}\left(\frac{\frac{d}{d\theta}f(\underline{X}_{(n)};\ \theta)}{f(\underline{X}_{(n)};\ \theta)}\right).\end{aligned}$$

Si, para simplificar las expresiones, denotamos $f(\underline{X}_{(n)};\ \theta)$ simplemente por f, tenemos

$$\begin{aligned}\frac{d^2}{d\theta^2}\ln f &= \frac{d}{d\theta}\left(f^{-1}\left(\frac{d}{d\theta}f\right)\right)\\ &= f^{-1}\left(\frac{d^2}{d\theta^2}f\right) - f^{-2}\left(\frac{d}{d\theta}f\right)\left(\frac{d}{d\theta}f\right).\end{aligned}$$

II.12. Expresiones alternativas de la Cota

De esta manera,

$$\frac{d^2}{d\theta^2}\ln f \quad = \quad f^{-1}\left(\frac{d^2}{d\theta^2}f\right) - f^{-2}\left(\frac{d}{d\theta}f\right)^2 .$$

Ahora, si se calcula la esperanza, se tiene

$$E\left(\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta)\right) \quad = \quad E\left(f^{-1}\left(\frac{d^2}{d\theta^2}f\right) - f^{-2}\left(\frac{d}{d\theta}f\right)^2\right)$$

$$= \quad E\left(f^{-1}\left(\frac{d^2}{d\theta^2}f\right)\right) - E\left(f^{-2}\left(\frac{d}{d\theta}f\right)^2\right)$$

II.12. Expresiones alternativas de la Cota

y, explícitamente, en términos de integrales

$$E\left(\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta)\right) \ = \ \int f^{-1}\left(\frac{d^2}{d\theta^2}f\right) f\ d\underline{x}_{(n)} \ - \int f^{-2}\left(\frac{d}{d\theta}f\right)^2 f\ d\underline{x}_{(n)}$$

$$= \ \int \left(\frac{d^2}{d\theta^2}f\right) d\underline{x}_{(n)} \ - \int \ \left[\left(\frac{d}{d\theta}f\right)\ /\ f\right]^2 \ f\ dx_{(n)}\,.$$

Si es posible intercambiar los operadores de diferenciación e integración, se obtiene,

$$E\left(\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta)\right) \ = \ \frac{d^2}{d\theta^2}\left(\int f\ d\underline{x}_{(n)}\right) \ - \ \int\left(\frac{d}{d\theta}\ln f(x_{(n)};\ \theta)\right)^2 \ f\ dx_{(n)}$$

II.12. Expresiones alternativas de la Cota

En resumen,

$$E\left[\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta)\right] \ = \ -E\left[\left(\frac{d}{d\theta}\ln f\left(x_{(n)};\ \theta\right)\right)^2\right].$$

De esta identidad se sigue una primera expresión alternativa para la cota de Cramér y Rao

$$CICR(\theta) \ = \ \frac{1}{-E\left(\ \frac{d^2}{d\theta^2}\ln f\left(\underline{X}_{(n)}\ ;\ \theta\right)\right)}.$$

Esta expresión alternativa es la primera de tres. Las otras dos se derivan del hecho

$$f\left(\underline{X}_{(n)};\ \theta\right) \ = \ \Pi_{i=1}^{n} f(X_i\ ;\ \theta).$$

II.12. Expresiones alternativas de la Cota

En efecto, si

$$f\left(\underline{X}_{(n)};\ \theta\right) \ = \ \Pi_{i=1}^{n} f(X_i\ ;\ \theta)$$

entonces,

$$\ln f\left(\underline{X}_{(n)};\ \theta\right) \ = \ \Sigma_{i=1}^{n} \ln f(X_i\ ;\ \theta)$$

y

$$\frac{d^2}{d\theta^2} \ln f\left(\underline{X}_{(n)};\ \theta\right) \ = \ \Sigma_{i=1}^{n} \frac{d^2}{d\theta^2} \ln f(X_i\ ;\ \theta)\,.$$

Ahora, puesto que las variables aleatorias

$$\frac{d^2}{d\theta^2} \ln f(X_i\ ;\ \theta)\ ; \quad i = 1, \dots, n.$$

son idénticamente distribuidas, se tiene que $E\left(\frac{d^2}{d\theta^2}\ln f\left(\underline{X}_{(n)}\,;\ \theta\right)\right) \ = \ n\,E\left(\frac{d^2}{d\theta^2}\ln f(X\,;\ \theta)\right)$.

II.12. Expresiones alternativas de la Cota

Y, por último,

$$CICR(\theta) \;=\; \frac{1}{-\,n\,E\left(\;\dfrac{d^2}{d\theta^2}\ln f(X\;;\;\theta)\;\right)}.$$

Finalmente, si se aplica la identidad entre el cuadrado de la primera derivada y la segunda derivada, en le caso en que n=1, se tiene que

$$E\left(\;\frac{d^2}{d\theta^2}\ln f(X\;;\;\theta)\;\right) \;=\; -\,E\left[\;\left(\frac{d}{d\theta}\ln f(X;\;\theta)\right)^2\;\right]$$

Con lo que se da lugar a las distintas expresiones alternativas de la $CICR(\theta)$.

II.12. Expresiones alternativas de la Cota

Así, tenemos cuatro representaciones, igualmente válidas, para la Cota Inferior de *Cramér* y *Rao*:

$$CICR(\theta) = \frac{1}{E\left\{\left(\frac{d}{d\theta}\ln f(\underline{X}_{(n)};\ \theta\right)^2\right\}}$$

$$CICR(\theta) = \frac{1}{-\,E\left(\frac{d^2}{d\theta^2}\ln f(\underline{X}_{(n)};\ \theta)\right)}$$

$$CICR(\theta) = \frac{1}{-\,n\,E\left(\frac{d^2}{d\theta^2}\ln f(X;\ \theta)\right)}$$

$$CICR(\theta) = \frac{1}{n\,E\left\{\left(\frac{d}{d\theta}\ln f(X;\ \theta\right)^2\right\}}$$

II.13. Mas ejemplos

Efectivamente algunos cálculos se facilitan cuando se utiliza la versión de la cota en términos de la segunda derivada y más aún cuando se utiliza una sola observación de la variable bajo estudio. Consideremos de nuevo el ejemplo 10.

***Ejemplo 10 (revistado)**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\mu \in \mathbb{R}$. Determine la $CICR(\mu)$ para la varianza de **todo** estimador insesgado de μ.*

En este caso

$$f(\,X\,;\,\mu) \;=\; (2\pi\sigma^2)^{-1/2}\, exp\left\{-\,\frac{1}{2\sigma^2}\,(X-\mu)^2\right\}$$

aplicando logaritmo,

$$\ln f(\,X\,;\,\mu) \;=\; -\frac{1}{2}\ln(2\pi\sigma^2)\;-\;\frac{1}{2\sigma^2}\,(X-\mu)^2$$

y derivando,

$$\frac{d}{d\mu}\ln f(\,X\,;\,\mu) \;=-\;\frac{1}{2\sigma^2}\;2\,(X-\mu)(-1)$$

II.13. Mas ejemplos

de forma que,

$$\frac{d}{d\mu}\ln f(\,X\,;\,\mu) \;=\; \frac{1}{\sigma^2}\,(X-\mu)$$

y derivando una segunda ocasión

$$\frac{d^2}{d\mu^2}\ln f(\,X\,;\,\mu) \;=\; -\,\frac{1}{\sigma^2}$$

resulta una constante, así que

$$-n\,E\left(\frac{d^2}{d\mu^2}\ln f(\,X\,;\,\mu)\right) \;=\; \frac{n}{\sigma^2}.$$

Por último, como ya sabíamos,

$$CICR(\mu) = \frac{\sigma^2}{n}.$$

II.13. Mas ejemplos

En el caso de la varianza la simplificación también es evidente

***Ejemplo 11 (revisitado)**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\sigma^2 > 0$. Determine la $CICR(\sigma^2)$ para la varianza de **todo** estimador insesgado de σ^2.*

De nuevo

$$f(\,X\,;\sigma^2) \;=\; (2\pi\sigma^2)^{-1/2}\, exp\left\{-\,\frac{1}{2\sigma^2}\,(X-\mu)^2\right\}$$

aplicando logaritmo,

$$\ln f(\,X\,;\sigma^2) \;=\; -\frac{1}{2}\ln(2\pi\sigma^2) \;-\; \frac{1}{2\sigma^2}\,(X-\mu)^2$$

y derivando,

$$\frac{d}{d\sigma^2}\ln f(\,X\,;\sigma^2) \;= -\frac{1}{2}\,\frac{2\pi}{2\pi\sigma^2} + \;\frac{1}{2\sigma^4}\,(X-\mu)^2$$

II.13. Mas ejemplos

al derivar por segunda vez se encuentra

$$\frac{d^2}{d(\sigma^2)^2}\ln f(\,X\,;\sigma^2)\;=\;\frac{1}{2}\,\frac{1}{\sigma^4}\;-\;\frac{1}{\sigma^6}\,(X-\mu)^2$$

de manera que

$$\begin{aligned}-n\,E\left(\frac{d^2}{d(\sigma^2)^2}\ln f(\,X\,;\sigma^2)\right)\;&=\;-\frac{1}{2}\frac{n}{\sigma^4}\;+\;\frac{n}{\sigma^6}\,Var(X)\\&=\;-\frac{1}{2}\,\frac{n}{\sigma^4}+\frac{n}{\sigma^6}\sigma^2\\&=\;\frac{n}{2\sigma^4}.\end{aligned}$$

II.14. Cramér y Rao parte 2

Así que, es inmediato concluir, como ya sabíamos también, que

$$CICR(\sigma^2) = \frac{2\sigma^4}{n}.$$

Con el cálculo de la cota y uno o varios estimadores insesgados, de los cuales se conocen sus varianzas, es posible saber si uno de esos candidatos es el ***MVUE*** de θ. El tema es que si no hay candidatos previamente, la cota se puede calcular y sería de interés saber si existe un estimador insesgado cuya varianza alcance la cota, es decir si existe el ***MVUE***. Para este fin es útil la segunda parte del Teorema de *Cramér* y *Rao*.

Teorema (Cramér y Rao, parte II). *Sea $\underline{X}_{(n)}$ una m. a. de una v. a. X, con f.d.p.g $f(x\,;\,\theta)$ con $\theta \in \mathbb{R}$. Entonces, si $\hat{\theta}$ es un estimador insesgado de θ, entonces $Var(\hat{\theta})$ alcanza la $CICR(\theta)$ si y solo si la función score de Cramér y Rao se puede expresar como*

$$U \;=\; \pm \frac{1}{CICR(\theta)}\left(\hat{\theta} - \theta\right).$$

II.14. Cramér y Rao parte 2

Demostración. Sea $\hat{\theta}$ un estimador insesgado de θ, entonces

$$Var(\hat{\theta}) = CICR(\theta),$$

$$\Leftrightarrow \qquad \left(Cov(U,\hat{\theta}\right)^2 = Var(\hat{\theta})\, Var(U)$$

$$\Leftrightarrow \qquad 4\left(Cov(U,\hat{\theta}\right)^2 - 4\, Var(\hat{\theta})\, Var(U) = 0$$

Pero $4\left(Cov(U,\hat{\theta}\right)^2 - 4\, Var(\hat{\theta})\, Var(U)$ es el discriminante de la ecuación de segundo grado

$$g(k) = Var(\hat{\theta})k^2 - 2kCov(\hat{\theta}, U) + Var(U)$$

$$= Var(U + k\hat{\theta}).$$

II.14. Cramér y Rao parte 2

Por lo tanto,

$$Var(\hat{\theta}) = CICR(\theta) \quad \Leftrightarrow \quad g(k) \text{ tiene una única raíz real.}$$

$$\Leftrightarrow \quad \text{existe una contante } k^* \text{ tal que } g(k^*) = 0$$

$$\Leftrightarrow \quad Var(U + k^*\hat{\theta}) = 0$$

$$\Leftrightarrow \quad U + k^*\hat{\theta} = c^*, \quad \text{con } c^* \text{ una constante.}$$

$$\Leftrightarrow \quad U = A\hat{\theta} + B,$$

con A y B constantes. Por tanto, hasta aquí, se ha probado que $\hat{\theta}$ es un estimador insesgado de θ, cuya varianza alcanza la $CICR(\theta)$, si sólo si U y $\hat{\theta}$ guardan una relación lineal perfecta. Es decir, si una es transformación lineal de la otra.

II.14. Cramér y Rao parte 2

Ahora bien, si $U = A\hat{\theta} + B$, es posible tener información más precisa acerca de las constantes A y B que las relacionan. Específicamente, sabemos que $E(U) = 0$. Así que, en particular, estas constantes deben satisfacer la ecuación

$$E\left(A\hat{\theta} + B\right) = AE\left(\hat{\theta}\right) + B$$

$$= 0.$$

Pero, además $\hat{\theta}$ es insesgado, de manera que $E\left(\hat{\theta}\right) = \theta$. Así, se tiene que

$$A\theta + B = 0$$

o, equivalentemente, $B = -A\theta$. De esta forma, es posible afirmar que $\hat{\theta}$ es un estimador insesgado de θ, cuya varianza alcanza la $CICR(\theta)$, si sólo si satisface la ecuación

$$U = A\left(\hat{\theta} - \theta\right).$$

II.14. Cramér y Rao parte 2

Si se procede de la misma forma con la varianza, se tiene que

$$
\begin{aligned}
Var(U) &= A^2\, Var\left(\hat{\theta} - \theta\right) \\
\Leftrightarrow \quad \frac{1}{CICR(\theta)} &= A^2\, CICR(\theta) \\
\Leftrightarrow \quad A^2 &= \frac{1}{\left(CICR(\theta)\right)^2} \\
\Leftrightarrow \quad A &= \pm \frac{1}{CICR(\theta)}.
\end{aligned}
$$

Por tanto, $\hat{\theta}$ es un estimador insesgado de θ, cuya varianza alcanza la $CICR(\theta)$, si y sólo si satisface la condición

$$U = \pm \frac{1}{CICR(\theta)} \left(\hat{\theta} - \theta\right). \ \square$$

II.15. De nuevo, ejemplos

Ilustremos este segundo teorema con algunos ejemplos.

Ejemplo 14. *Sea* $\underline{X}_{(n)}$ *una m.a. de una v. a.* X *con distribución* $Bernoulli(\theta)$*, donde* $\theta \in (0,1)$*. Encuentre un estimador insesgado de* θ *cuya varianza alcance la* $CICR(\theta)$*.*

En el ejemplo 9 se comprobó que

$$U = \frac{\Sigma X_i - n\theta}{\theta(1-\theta)}$$

expresión que se puede escribir también como

$$U = \frac{n}{\theta(1-\theta)} \left(\overline{X} - \theta \right)$$

de manera que por el teorema 2, y dado que $\overline{X}$ es un estimador insesgado de θ, se concluye que $\overline{X}$ es ***el*** estimador insesgado de varianza mínima. Más relevante, se concluye que este es el único ***MVUE.***

II.15. De nuevo, ejemplos

***Ejemplo 15**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\mu \in \mathbb{R}$. Identifique un estimador insesgado de μ cuya varianza alcance la $CICR(\mu)$.*

En el ejemplo 10, se probó que

$$U = \frac{n}{\sigma^2}\left(\overline{X} - \mu\right),$$

así que las conclusión es inmediata. $\overline{X}$ es el único ***MVUE*** de μ.

***Ejemplo 16**. Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con distribución $Normal(\mu, \sigma^2)$ donde $\sigma^2 > 0$. Determine un estimador insesgado de σ^2cuya varianza alcance la $CICR(\sigma^2)$.*

De los cálculos en el ejemplo 11, se sigue que

$$U = -\frac{n}{2\sigma^2} + \frac{1}{2\sigma^2}\left[\frac{n}{\sigma^2}\,\hat{\sigma}^2\right]$$

II.15. De nuevo, ejemplos

donde

$$\hat{\sigma}^2 = \frac{1}{n} \Sigma_{i=1}^{n} (x_i - \mu)^2.$$

Equivalentemente se tiene

$$U = \frac{n}{2\sigma^4} [\, \hat{\sigma}^2 - \sigma^2 \,].$$

Por tanto, se tiene que el estimador $\hat{\sigma}^2$ es el ***MVUE*** de σ^2, cuando la esperanza μ es conocida. Más informativo, también se sabe que, *en el caso que en que μ es desconocido, no existe un estimador insesgado de σ^2 cuya varianza alcance la $CICR(\sigma^2)$.*

Consideremos un ejemplo más.

Ejemplo 17. *Sea $\underline{X}_{(n)}$ una m.a. de una v. a. X, con función de densidad $f(x;\lambda) = \lambda\, exp(-\lambda\, x)$ con $\lambda > 0$ y $x > 0$. Determine un estimador insesgado de λ cuya varianza alcance la $CICR(\lambda)$.*

II.15. De nuevo, ejemplos

Del ejemplo 12, podemos recordar que

$$U \;=\; \frac{n}{\lambda} - \Sigma_{i=1}^{n} x_i$$

y $CICR(\lambda) = \lambda^2/n$. Como consecuencia, para tener como factor común el inverso de la $CICR(\lambda)$, la única posibilidad es la siguiente:

$$U \;=\; -\frac{n}{\lambda^2}\left(\lambda^2\,\overline{X} - \lambda\right).$$

Puesto que $\lambda^2\,\overline{X}$ no es un estimador, se concluye que no existe el estimador insesgado de λ cuya varianza alcance la $CICR(\lambda)$. Es interesante observar que la expresión alternativa

$$U \;=\; -n\left(\overline{X} - \frac{1}{\lambda}\right)$$

sugiere que $\overline{X}$ podría ser el ***MVUE*** de $\xi = 1/\lambda$, el valor esperado de X.

II.15. De nuevo, ejemplos

Sin embargo, el teorema no se aplica directamente en ese caso, ya que la cota se calculó para los estimadores de λ y no de ξ.

De hecho, este comentario sugiere una línea de investigación: ¿Cómo se modifica el teorema y cuál es el resultado si se considera una reparametrización del parámetro original del modelo? Aún en general, como cambia si en vez del parámetro original θ, se considera una función $\psi = \psi(\theta)$, no necesariamente una reparametrización.

Tarea. *Determine si existe y, de existir, cual es la expresión para la $CICR(\phi)$ para la varianza de los estimadores insesgados de $\phi = g(\theta)$, donde ϕ es una reparametrización del parámetro θ que determina al modelo $f(x;\ \theta)$.*

Tarea. *¿Cómo se modifica la $CICR(\theta)$ si se calcula para la varianza de todos los estimadores sesgados de θ, cuyo sesgo es igual a una constante c? ¿Qué pasa si el sesgo es una función de θ?*

II.15. De nuevo, ejemplos

En este punto ya se cuenta con una variedad de criterios que permiten evaluar la calidad de los estimadores pero sigue pendiente el tema de los mecanismos generales para proponer las funciones estimadoras.

Más allá de la idea de *analogía*, no se ha propuesto un mecanismo que permita producir estimadores en situaciones generales. El objetivo es que frente a un problema de estimación puntual general, donde se tienen como insumos: la función de distribución de la variable aleatoria de interés X, la especificación del parámetro θ que se desea estimar y, por supuesto, una muestra aleatoria de X, sea posible aplicar una algoritmo a esos insumos para que, de manera automática, arroje una función estimadora.

El objetivo parece ambicioso pero, es perfectamente alcanzable, como se discutirá en la siguiente sección, ***Métodos de Estimación Puntual***.